花间识微：面向小规模五类花卉细粒度分类的数据审计与迁移集成框架

Reading Petals: A Data-Auditing and Transfer-Ensemble Framework for Fine-Grained Five-Class Flower Classification with Small Data

摘要

花卉识别是典型的细粒度视觉任务：类间差异常小于类内差异，公开数据中又混有无关图像。本文提出一套面向小规模、标签带噪花卉数据的数据审计与迁移集成框架。框架由三部分组成：以 MD5/dHash 聚类为单位的去泄漏划分、置信度排序—物体筛查—原图与来源复核的三级标签审计，以及从零结构到 ImageNet 预训练主干的受控训练与概率集成。在 3,670 张五类图像上，框架将评测口径与模型选择分开：从零训练的最佳结构 ResidualCNN+SE（1.23M 参数）达到 86.39% 测试准确率；迁移学习将单模型提升至 96.91%，256 输入降低 roses/tulips 的验证集双向混淆（16→10）；ConvNeXt-Base-256 与 EfficientNetV2-M-224 的等权概率集成在清洗测试集（$n = 544$）上取得 **97.43%** 准确率与 **0.9737** Macro-F1，错误 14 个。清洗使评测口径更可靠，但清洗后重训（96.69%）低于原模型（96.88%），表明限制性能的主要因素已由标签噪声转向任务可分性与样本规模。二项标准误约 0.7 pp；97.4% 只适用于当前标注版本与测试集。

关键词：细粒度图像分类；卷积神经网络；迁移学习；通道注意力；集成学习；标签噪声；可复现性

Abstract. Flower recognition is a fine-grained vision problem: between-class differences can be smaller than within-class variation, and community datasets often contain irrelevant images. This paper presents a data-auditing and transfer-ensemble framework for small, label-noisy flower datasets. The framework has three components: cluster-level splitting based on MD5/dHash to prevent near-duplicate leakage, a three-stage label audit (confidence ranking, object screening, and source verification), and controlled training with probability ensembling from scratch CNNs to ImageNet-pretrained backbones. On 3,670 images from five classes, the framework separates evaluation conditions from model selection. The best from-scratch model (ResidualCNN+SE, 1.23M parameters) reaches 86.39% test accuracy. Transfer learning raises a single model to 96.91%, and 256-pixel inputs reduce roses/tulips confusion on validation from 16 to 10. An equal-weight ensemble of ConvNeXt-Base-256 and EfficientNetV2-M-224 attains 97.43% accuracy and 0.9737 macro-F1 on the cleaned test set ($n = 544$), with 14 errors. Cleaning improves evaluation hygiene but not accuracy upon retraining (96.69% versus 96.88%), indicating that the main limitation has shifted from label noise to task separability and sample size. The binomial standard error is about 0.7 pp; the 97.4% result applies to the current annotation version and test set.

Keywords: fine-grained image classification; convolutional neural networks; transfer learning; channel attention; ensemble learning; label noise; reproducibility

1 引言

1.1 问题背景

花卉识别属于细粒度视觉分类：类别由花瓣形状、层次、花心结构和色彩共同决定，类间差异可能小于同一种花卉在花苞、盛放、凋谢、特写与远景下的外观差异。公开图像多来自 Flickr，拍摄距离、光照、背景和后期风格不受控，模型容易把草地、花园栅栏或暖色调当作类别线索。本文

使用的五类花卉数据只有约 2.5k 张训练图，从零训练难以获得稳定的细粒度表征。其中 roses 与 tulips 的花型、花瓣层次接近，是本文最难的混淆对。

这些因素使分类性能同时受模型、数据和评测口径影响。只比较网络结构，无法判断增益来自容量、预训练还是标签质量；只在含噪测试集上报告准确率，也无法区分模型误差与标注错误。模型设计的目标是：在不增加标注成本的前提下，利用 ImageNet 预训练表征降低 roses/tulips 的混淆，并用互补分支减少单模型的偶然错误。

1.2 主要贡献

本文的贡献有三点。第一，提出以 MD5/dHash 聚类为单位的去泄漏划分与三级标签审计流程，形成逐条可追溯的清洗版数据。第二，在同一协议下构建受控训练与评估流程，覆盖 5 种从零结构、4 种增强策略、3 个预训练主干、2 种输入分辨率以及 TTA 与概率集成。第三，在 3,670 张五类图像上验证该框架，并给出二项标准误与选择偏差分析。

1.3 与已有工作的关系

细粒度识别的主流路线有三类：一是部件/双线性表示，通过定位判别性部位或建模二阶特征提升类间可分性 [8, 9]；二是强主干与迁移学习，自 AlexNet[1] 以来，卷积网络在大规模数据上预训练学习通用视觉表征，再在小数据集上微调 [2, 4, 5]；三是数据与训练策略，包括数据增强、标签平滑、EMA、TTA 与集成 [10, 11, 12, 13]。本文将这些手段组织为一个面向小规模、标签带噪数据的框架，并在同一评测口径下验证其收益与边界。

在数据侧，Nilsback 与 Zisserman 的工作表明，花卉数据集的类别边界与拍摄条件会显著影响识别难度 [7]；在标签侧，Confident Learning 一类方法强调应显式估计“标注是否可信”，而不是把测试集当作金标准 [14]。本文的标签审计受这一思想影响，但保留人工最终裁决，避免用模型预测替代事实判断。

2 模型设计

2.1 最终方案

最终方案由两个互补的卷积分支组成：同一张花卉图像分别经过 ConvNeXt-Base-256 与 EfficientNetV2-M-224，得到两组五类概率，再等权平均。图 1 给出推理流程。分支 A 使用 256×256 输入（短边缩放 288 后中心裁剪），分支 B 使用 224×224 输入（短边缩放 256 后中心裁剪）。两个分支都从 ImageNet 预训练权重初始化，替换 5 类分类头后全参数微调。

推理时，每个分支先对原图与水平翻转图分别前向，平均两次 softmax 输出；两个分支的概率再等权平均，取最大概率类别：

$$\bar{p}(y \mid x) = \frac{1}{4} \sum_{m \in \{A,B\}} \sum_{t \in \{0,1\}} p_m(y \mid T_t(x)), \qquad \hat{y} = \arg\max_y \bar{p}(y \mid x), \tag{1}$$

其中 T_0 为恒等变换，T_1 为水平翻转。两个分支的参数量分别为 87.57M 与 52.86M，合计约 140M；推理需要 4 次前向（两模型 $\times$ 翻转 TTA）。

2.2 分支训练

ConvNeXt-Base 分支使用 256×256 输入，训练 6 个 epoch，AdamW（$lr = 2\times10^{-5}$，$wd = 0.01$），余弦退火，标签平滑 0.1，EMA 衰减 0.995，batch size 32。EfficientNetV2-M 分支使用 224×224

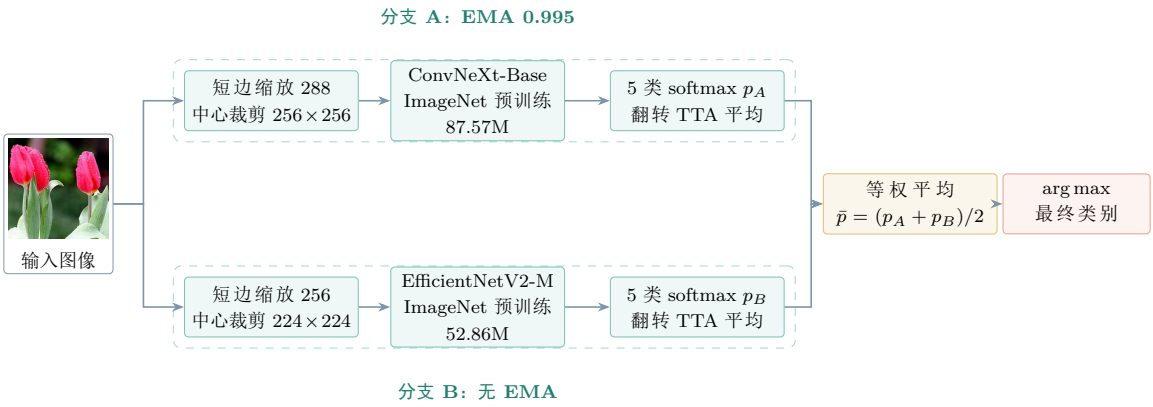


图 1：最终方案。两个分支分别输出五类概率，经翻转 TTA 与等权平均后取最大概率类别。

输入，训练 5 个 epoch，AdamW（$lr = 10^{-4}$，$wd = 10^{-4}$），标签平滑 0.1，不使用 EMA。训练目标为标签平滑交叉熵（$\varepsilon = 0.1$）；两个分支都使用随机缩放裁剪、水平翻转与颜色抖动，验证与测试只做确定性缩放和中心裁剪。

选择这两个分支的依据是归纳偏置的互补性。ConvNeXt 的 7×7 深度可分离卷积与大核设计偏向形状与全局结构；EfficientNetV2-M 的复合缩放与 MBConv/Fused-MBConv 偏向多尺度纹理。二者在不同分辨率下训练，错误相关性较低。EMA 只用于 ConvNeXt 分支：该分支训练轮数略多，滑动平均能降低模型选择的方差；EfficientNet 分支在 5 轮内已收敛，EMA 的收益有限。

2.3 对照模型

为判断最终方案的收益，本文保留三类对照。SimpleCNN 由 4 个卷积块组成，通道数 $32 \to 64 \to 128 \to 256$，全局平均池化后接 5 类线性层，约 1.17M 参数。ResidualCNN 在相同通道计划上加入残差捷径，通道变化时用 1×1 卷积投影，约 1.22M 参数；Residual+SE 在后两个 stage 加入压缩比 16 的 SE 通道注意力，约 1.23M 参数。迁移对照包括 MobileNetV3-Small（1.52M 参数）与 EfficientNetV2-M（52.86M 参数），训练配置与分支 B 相同或更短。所有对照使用同一划分、同一评估变换与同一随机种子。

3 数据与实验设置

3.1 数据概况

数据集包含 5 个类别、3,670 张 JPEG 图像，全部为 RGB，无损坏文件。表 1 汇总了类别规模与基本视觉统计。dandelion 最多（898 张，24.5%），daisy 最少（633 张，17.2%），最大/最小类别比约 1.42，属于轻度不平衡；因此本文只使用分层划分，不做重采样或类别加权，以免把“类别先验”与“模型能力”混在一起。

图 2 的两个统计直接影响输入设计。左图显示分层划分后的类别比例与原始分布一致；右图给出短边累积分布：73.4% 的图像短边不小于 224，35.0% 不小于 288。把输入从 224 提到 256（短边缩放 288）时，约 65% 的样本仍要上采样，原生细节有限。这一约束解释了后文 256 输入只在 roses/tulips 等难类上带来小幅改善，而不改变总体测试准确率。

表 1: 数据集类别分布与视觉统计。短边 ≥224 表示该比例的原图在 224 输入下不需要上采样。亮度与饱和度归一化到 $[0, 1]$。

类别	图像数	占比	平均尺寸	宽高比	短边 ≥224	亮度	饱和度
daisy	633	17.2%	359 × 271	1.31	72.5%	0.48	0.42
dandelion	898	24.5%	367 × 274	1.32	77.5%	0.47	0.48
roses	641	17.5%	364 × 275	1.31	79.1%	0.53	0.47
sunflowers	699	19.0%	360 × 270	1.32	73.4%	0.56	0.59
tulips	799	21.8%	372 × 269	1.37	65.0%	0.54	0.51
合计	3,670	100%	365 × 272	1.33	73.4%	0.52	0.49

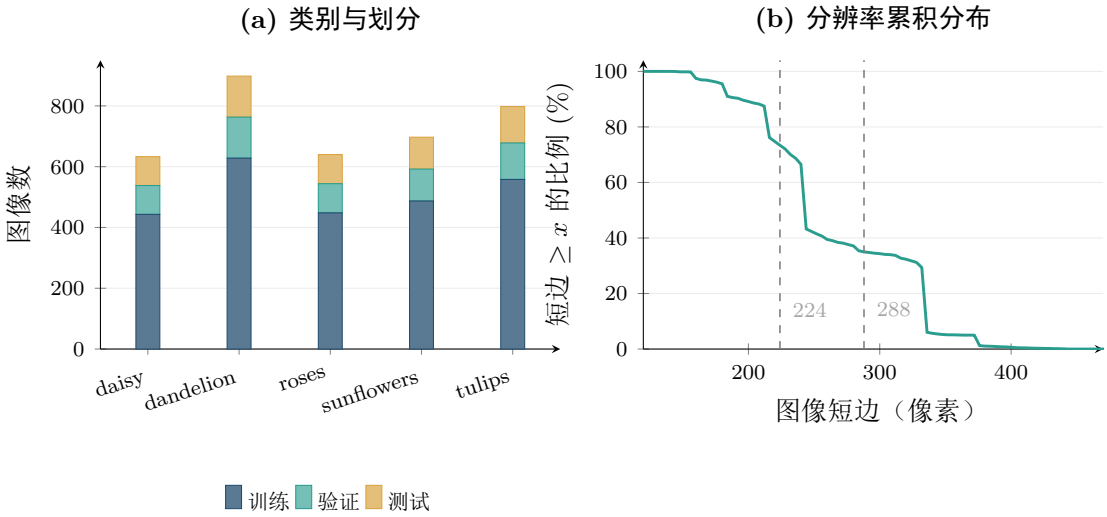


图 2: 数据总览。(a) 分层划分后的类别构成；(b) 图像短边的累积分布，虚线标出 224 与 288 两个关键阈值。仅约 35% 的图像能原生支持 288 短边，这限制了 256 输入的实际收益。

3.2 颜色与背景偏置

各类平均亮度在 0.47–0.56 之间，差异有限；色相分布差异明显：dandelion 与 sunflowers 集中在黄橙色相，roses 偏红/品红，daisy 与 tulips 更分散。仅用颜色直方图的线性分类器就能取得较高准确率，卷积网络也可能把背景颜色、草地比例和拍摄风格当作线索。类平均图显示各类构图与背景占比存在系统差异。为降低捷径风险，训练使用颜色抖动与随机缩放裁剪，并把增强消融作为独立实验检验颜色扰动的作用；Grad-CAM 定位分析留作后续工作。

3.3 重复检测与数据划分

重复样本是小型数据集上最常见的隐性泄漏源：同一张图或同一场景的轻微变体若同时出现在训练集与测试集，指标会被系统性高估。本文用两级指纹处理该问题。完全重复用文件 MD5 判定；近重复用 64 位 dHash：将图像转为 9×8 灰度图，比较水平相邻像素得到 64 位指纹 h，两张图像的汉明距离为

$$d_H(h_i, h_j) = \mathrm{popcount}(h_i \oplus h_j). \tag{2}$$

当 $d_H \le 4$ 时用并查集合并为同一簇，划分时以簇为最小单位，保证同一簇只进入训练/验证/测试集之一。

原始数据中检出 3 组完全重复（6 张）与 17 对近重复（34 张，占 0.9%），其中 1 组完全重复跨类别冲突（同一张图同时出现在 roses 与 tulips，无法确定唯一标签）。处理策略是：跨类冲突整组剔除（2 张），同类完全重复每组保留一张（剔除 2 张），近重复簇整体分入同一划分。最终使用 3,666 张，按类别分层划分为 2,564 / 551 / 551（约 70% / 15% / 15%），校验结果为 **0 个簇跨越划分**。表 2 列出原始与清洗两个版本的逐类划分。

表 2: 两个数据版本的划分。原始版本用于训练与消融；清洗版用于最终评测。清洗只删除样本，不改变划分归属，因此两版可逐样本对应。

类别	原始划分（3,666）			清洗版（3,609）				剔除
	训练	验证	测试	训练	验证	测试	合计	
daisy	443	95	95	442	95	95	632	1
dandelion	628	135	135	628	135	135	898	0
roses	448	96	96	427	89	95	611	29
sunflowers	487	105	105	485	105	104	694	3
tulips	558	120	120	545	114	115	774	24
合计	2,564	551	551	2,527	538	544	3,609	57

3.4 预处理与增强

所有图像统一转为 RGB，并按 ImageNet 统计量归一化：

$$\hat{x}_c = \frac{x_c - \mu_c}{\sigma_c}, \qquad \mu = (0.485, 0.456, 0.406), \quad \sigma = (0.229, 0.224, 0.225). \tag{3}$$

224 模型采用 Resize(256) → CenterCrop(224)；256 模型采用 Resize(288) → CenterCrop(256)。训练增强包括随机缩放裁剪（面积比例 0.65–1.0，宽高比 0.8–1.25）、水平翻转与颜色抖动（亮度/对比度/饱和度 0.2，色相 0.05）；关于图像增强的系统综述可参见 [16]。验证与测试只做确定性的缩放与中心裁剪，且同一张图两次前向的输出完全一致。图 3 显示同一张图在四种变换下的视图；随机裁剪会改变构图与背景比例，这类与类别无关的因素应尽量从模型中排除。

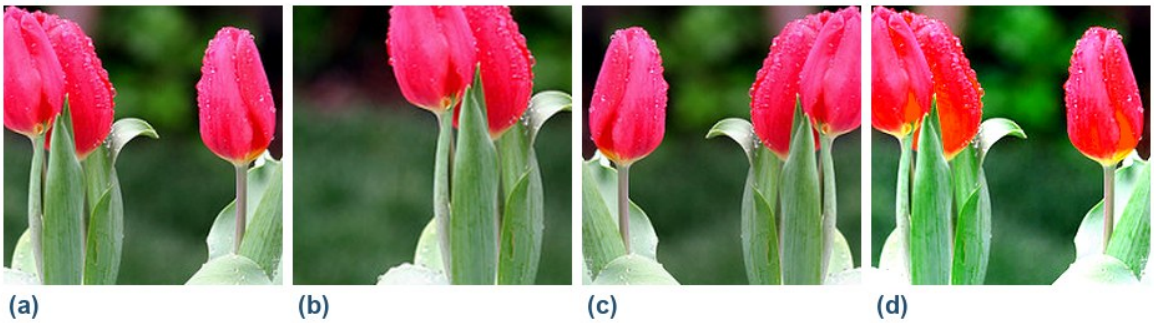


图 3: 预处理与增强示例。(a) 确定性中心裁剪（验证/测试）；(b) 随机缩放裁剪；(c) 水平翻转；(d) 颜色抖动（近似训练时的 ColorJitter）。(b)–(d) 只作用于训练集。

3.5 标签审计与两版测试集

3.5.1 动机

误差分析中有一类错误无法由模型能力解释：roses 的错分样本中有车辆、建筑和食物，tulips 的错分样本中有风信子田。若测试集包含这类图像，准确率同时低估模型能力并高估数据质量；训练集中的无关图像还会把非花卉概念带入决策边界。标签审计因此与模型训练同等重要。审计要回答的是一个可核查的问题：这张图是否确实包含该类别定义下的真实花卉？只有确定不包含或确定属于另一物种时才删除；对“有花但物种存疑”的样本保守保留。

3.5.2 审计流程

审计分三步：用训练好的 ConvNeXt-Base 对全部图像推理，按最大 softmax 置信度升序排列，并导出验证集与测试集的错分样本；用 ImageNet 预训练分类器筛查车辆、建筑、动物、景观、食物和人物活动等非花卉候选；对争议样本查看高分辨率原图，结合 Flickr 页面标题、作者标签与 oEmbed 元数据确认拍摄对象，无法确认时保留并记录复核标记。最终清单包含 64 条决策：57 条排除、7 条保留；每条记录保留证据与来源，便于追溯。

3.5.3 判定准则

排除的对象是图中不存在符合类别定义的真实花卉，或内容为车辆、建筑、风景、人物活动、食物、插画/装饰等明确无关对象，或主体明显属于另一物种（如把风信子标成 tulips）。图中存在目标花卉但物种或品种存疑、混合场景中目标可见、或为可识别的营养器官与种子头时，保留样本并记录不确定性。清洗只做删除，保持原划分归属；两版共享同一评估协议，清洗前后的差异可归因于样本集合变化，而不是划分变化。

3.5.4 审计结果

审计共排除 57 张（训练集 37、验证集 13、测试集 7），占 3,666 张的 1.55%。按问题类型可分为三类（表 3、图 4）：**无关场景或物体** 31 张（车辆、建筑、人物活动、食物、喷泉、茶杯等），**非真实花卉描绘** 19 张（绘画、插画、装饰、蛋糕糖霜花、光雕），**类别不符** 7 张（风信子田、非玫瑰的复合花、三叶草、蓝色穗状花境等）。图 5 展示 6 个例子，覆盖上述三类。

表 3: 清洗版的排除清单统计。占比以 57 张排除样本为分母。

问题类型	训练	验证	测试	合计	占排除数
无关场景或物体	24	4	3	31	54.4%
非真实花卉描绘	9	7	3	19	33.3%
类别不符（另一物种）	4	2	1	7	12.3%
合计	37	13	7	57	100%

3.5.5 审计的边界

审计是候选驱动的：复核范围是 383 张高风险候选，57 张是已确认无关的数量，数据集的真实噪声率可能更高。测试集删除 7 张（551→544），roses 与 tulips 分别减少 1 张和 5 张，逐类指标约有 0.5–1 pp的波动，比较必须在同一测试集上进行。清洗只移除错误监督，不增加新信息，不能保证重训一定更好；第 4 节的结果说明了这一点。

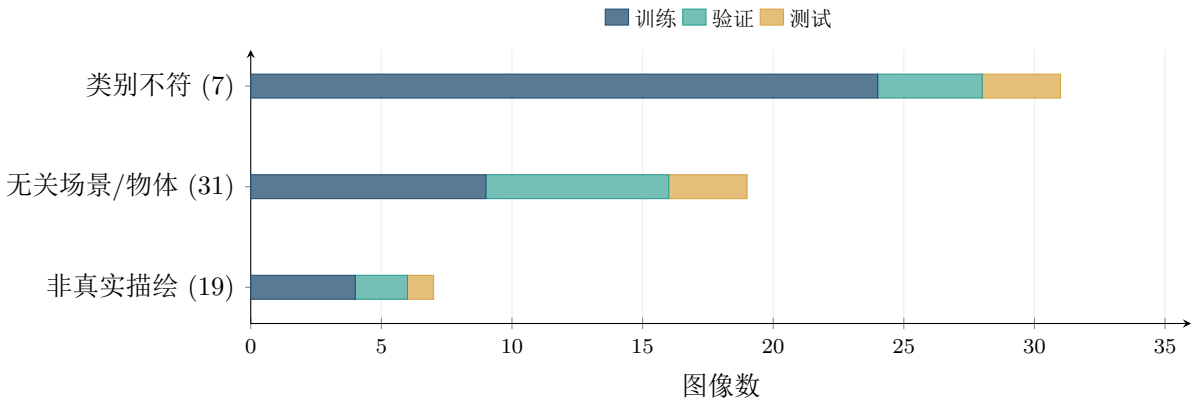


图 4: 标签审计的排除构成。大多数被排除样本位于训练集，但测试集的 7 张排除会直接改变最终评测口径（551→544）。

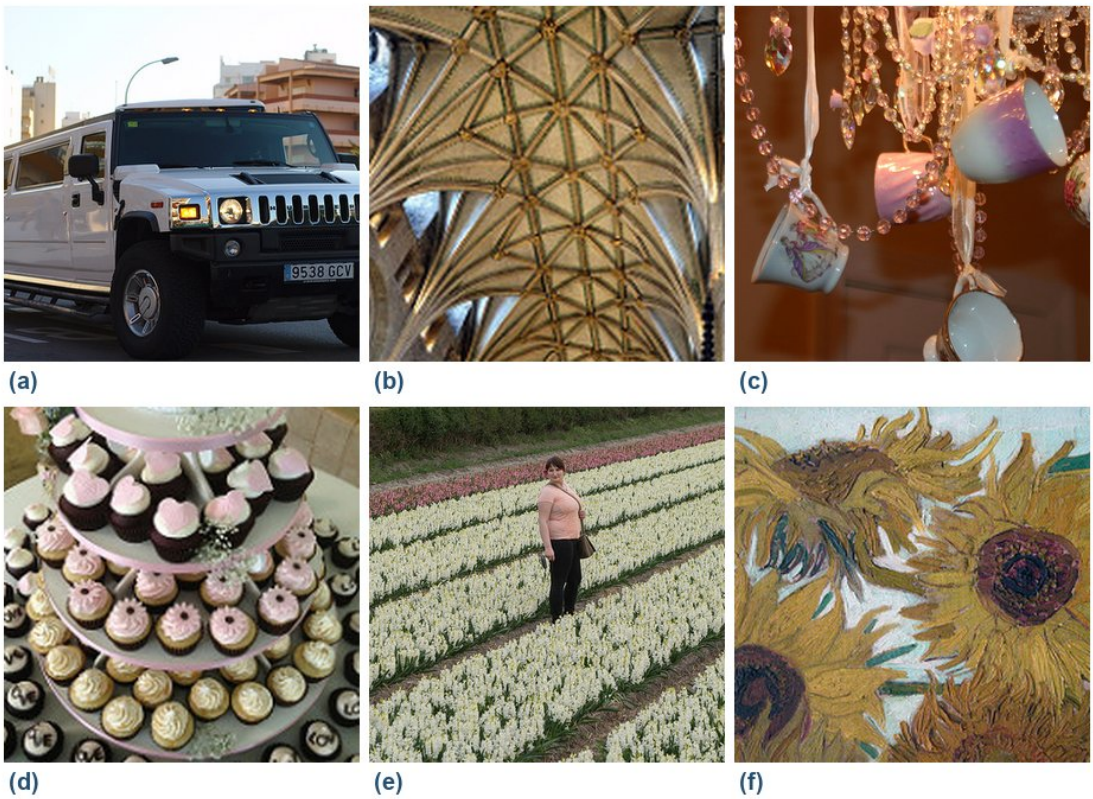


图 5: 标签噪声示例（均为原图中心裁剪）。(a) 白色悍马车被标为 roses；(b) 哥特式穹顶被标为 roses；(c) 茶杯挂饰被标为 roses；(d) 纸杯蛋糕塔被标为 roses；(e) 风信子花田被标为 tulips；(f) 向日葵油画被标为 sunflowers。

3.6 数据与评估流程

该框架需要同时处理两个问题：训练与评测之间的近重复泄漏，以及模型误差与标签误差的区分。图 6 概括了处理流程。原始图像先按 MD5 与 dHash 聚类，去重后以簇为单位分层划分为 2,564 / 551 / 551；随后用训练好的 ConvNeXt 排序候选、用 ImageNet 分类器筛查非花卉物体，再结合原图与 Flickr 元数据人工复核，得到 2,527 / 538 / 544 的清洗版划分。原始划分用于训练与早期消融，清洗版只用于最终评测；清洗只删除样本、不改变样本归属，因此两版指标可以逐样本对应。

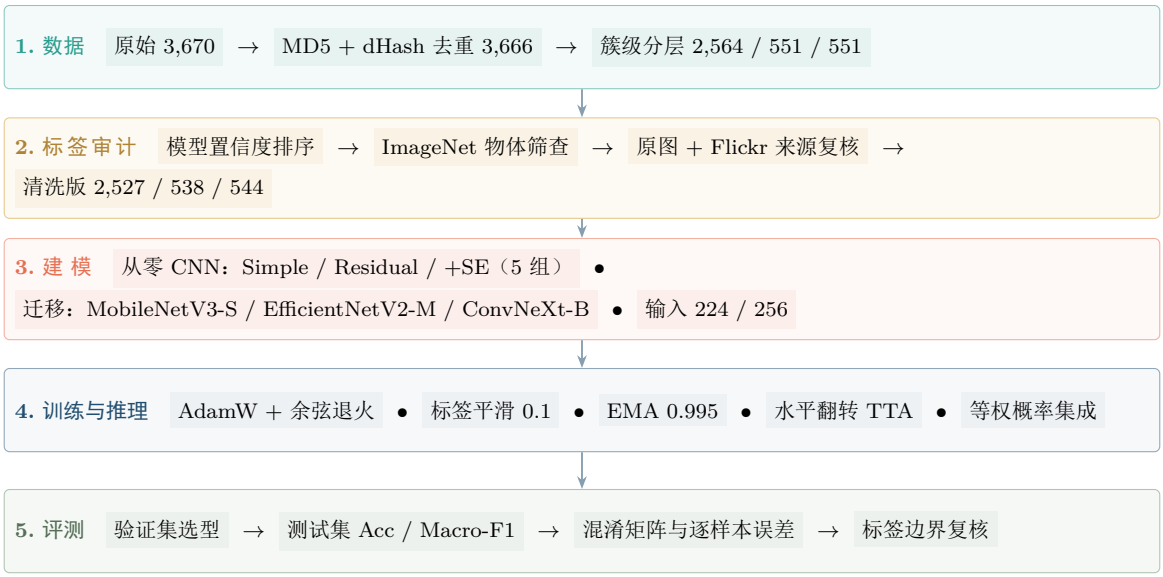


图 6: 研究框架。数据侧先做去重与簇级分层，再做标签审计；模型侧在同一划分上完成从零训练、迁移学习与集成；最终在清洗版测试集上报告结果，并把残余错误反馈到标签边界复核。

3.7 训练与评估协议

3.7.1 实验环境与统一协议

全部实验在单张 NVIDIA GeForce RTX 5090 Laptop GPU（24,463 MiB）上完成，Python 3.12 + PyTorch 2.x（CUDA 13.0），混合精度训练。所有模型共享同一份划分清单、同一套评估变换与同一随机种子（42），主要配置见表 4。

表 4: 实验矩阵。所有模型均使用 AdamW、余弦退火与标签平滑 0.1；迁移模型另加 EMA 与 TTA。

阶段	模型	输入	epochs	学习率	正则	目的
基线	SimpleCNN	224	30	10^{-3}	–	建立参照
长训练	SimpleCNN	224	80	10^{-3}	–	训练长度效应
结构	Residual / deep / +SE	224	80	10^{-3}	–	归纳偏置
增强	旋转 / 裁剪 / hue / Mixup	224	80	10^{-3}	–	增强策略
迁移	MobileNetV3-Small	224	8	3×10^{-4}	–	轻量部署
迁移	EfficientNetV2-M	224	5 / 10	10^{-4} / 5×10^{-5}	EMA+TTA	主干对比
迁移	ConvNeXt-Base	224	5 / 8	10^{-4} / 5×10^{-5}	EMA+TTA	单模型最佳
分辨率	ConvNeXt-Base	256	6	2×10^{-5}	EMA+TTA	细节收益
清洗	ConvNeXt-Base	256	20	10^{-5}	EMA+TTA	标签清洗
集成	ConvNeXt-256 + EffNetV2-M	256/224	–	–	TTA	最终方案

3.7.2 模型选择与评估协议

验证集承担三项选择：最佳 epoch、输入分辨率与集成子集；测试集只用于报告最终选中的配置。即便如此，同一测试集上仍比较了多个方案，存在轻微的选择偏差，第 4.7 节给出多种子与交叉验证的建议。

3.7.3 评价指标与统计不确定性

对 N 个样本，准确率与宏平均 F1 为

$$\mathrm{Acc} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}[\hat{y}_i = y_i], \tag{4}$$

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = \frac{2P_cR_c}{P_c + R_c}, \tag{5}$$

$$\text{Macro-F1} = \frac{1}{K}\sum_{c=1}^{K} F1_c. \tag{6}$$

同时记录混淆矩阵、各类别 F1 与 roses/tulips 双向混淆数。验证集用于选择 epoch、分辨率与集成组合；测试集用于最终报告。由于测试集只有 544–551 张，准确率的二项标准误为

$$\mathrm{SE}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{N}} \approx 0.7\,\mathrm{pp} \quad (\hat{p} \approx 0.97,\ N \approx 550), \tag{7}$$

对应的 95% Wilson 区间约为 $[95.7\%, 98.5\%]$。0.2–0.5 pp的差异通常只对应 1–3 张图，不能据此宣称某个模型显著更好；更可靠的比较需要多种子或交叉验证。

4 实验结果与分析

最终方案在同一份 544 张清洗测试集上评估：双模型集成达到 97.43% 准确率与 0.9737 Macro-F1，错误 14 个；方案中的 ConvNeXt-256 单模型为 96.88%，错误 17 个，最佳单模型 ConvNeXt-224 为 96.91%。集成相对最佳单模型提升 0.52 pp，错误数从 17 降到 14。表 5 与表 6 给出单模型与集成的完整对照。

4.1 主结果：集成与单模型

两个成员的归纳偏置不同。ConvNeXt 使用 7×7 深度可分离卷积与大核设计，偏向形状与全局结构；EfficientNetV2-M 使用复合缩放与 MBConv/Fused-MBConv，偏向多尺度纹理。二者在不同分辨率下训练（256 与 224），错误相关性较低，等权平均能带来互补。把同源的 ConvNeXt-清洗重训-256 再加进来构成三模型集成，准确率反而降到 97.24%：成员高度相关，平均只是在同一个意见上反复投票，同时稀释了 EfficientNet 的多样性。

表 5: 最终候选方案对照。原始测试集 551 张，清洗测试集 544 张；两组指标不可逐项直接比较。

方案	评测集	准确率	Macro-F1	错误数
ConvNeXt-224 + EMA + TTA（单）	原测试集	96.91%	0.9683	17/551
ConvNeXt-256 + EMA + TTA（单）	原测试集	96.73%	0.9669	18/551
EfficientNetV2-M-224（单）	原测试集	96.19%	0.9615	21/551
ConvNeXt-256 + EffNetV2-M（集成）	原测试集	**97.46%**	**0.9742**	**14/551**
ConvNeXt-256（单）	清洗测试集	96.88%	0.9680	17/544
EfficientNetV2-M（单）	清洗测试集	96.69%	0.9665	18/544
ConvNeXt-256 + EffNetV2-M（集成）	清洗测试集	**97.43%**	**0.9737**	**14/544**
三模型集成（+ ConvNeXt-清洗重训-256）	清洗测试集	97.24%	0.9715	15/544

最终集成在清洗测试集上的 daisy、dandelion、sunflowers F1 均在 0.979 以上；tulips（0.952）与 roses（0.963）较低（表 6）。其余类别的主要错误是零星的背景/构图混淆，roses 与 tulips 之间存在真实的视觉重叠。图 7 给出最终集成的混淆矩阵。

表 6: 最终集成在清洗测试集上的分类别指标（$n = 544$）。

类别	Precision	Recall	F1-score	Support
daisy	0.979	0.979	0.979	95
dandelion	0.985	0.993	0.989	135
roses	0.958	0.968	0.963	95
sunflowers	0.990	0.981	0.986	104
tulips	0.956	0.948	0.952	115
Macro avg	0.974	0.974	**0.974**	544
Accuracy		**0.9743**		544

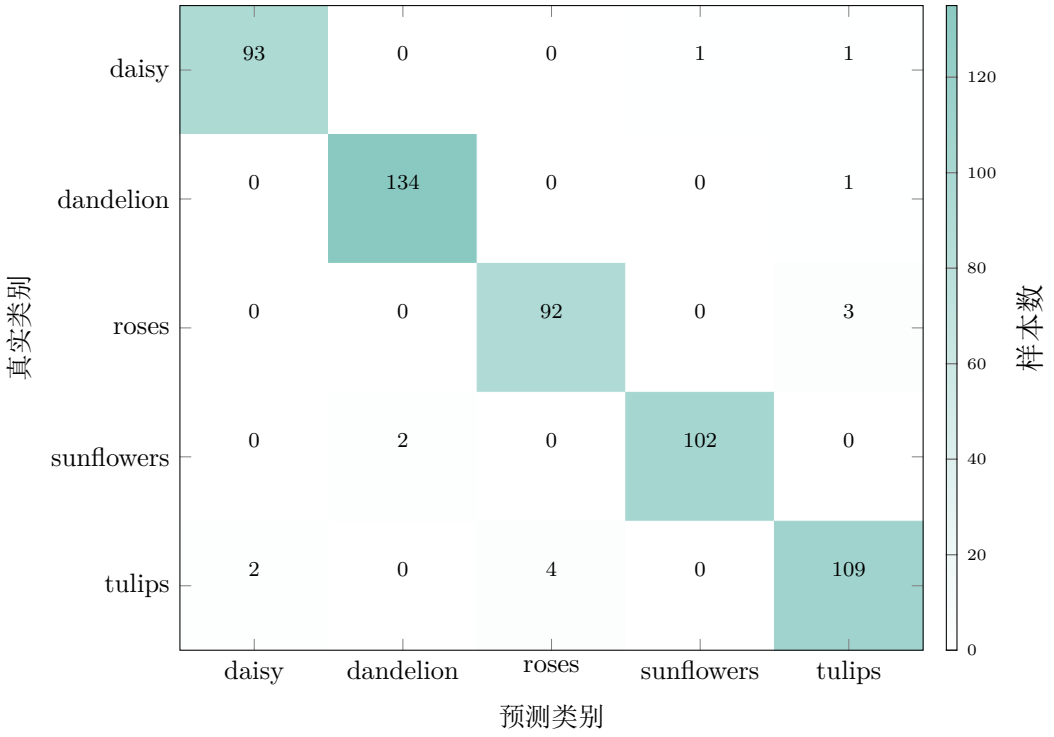


图 7: 最终集成在清洗测试集上的混淆矩阵。对角线分别为 97.9%、99.3%、96.8%、98.1%、94.8%；14 个错误中有 7 个发生在 roses 与 tulips 之间。

4.2 从零基线

4.2.1 从零训练的上限

训练长度首先暴露出容量与泛化之间的矛盾。SimpleCNN 从 30 轮延长到 80 轮，验证准确率由 83.67% 升到 87.66%，测试准确率由 79.85% 升到 84.76%（表 7）。30 轮明显欠拟合，但 80 轮也没有解决泛化：最佳 epoch 75 时，无增强训练集准确率为 95.87%，验证集为 87.66%，差距 8.21 pp；训练损失继续下降，验证损失趋平。图 8(c) 显示这一差距在第 20 轮后迅速扩大，60 轮后稳定在 8–9 pp。

表 7: 从零训练模型对比（原始 551 张测试集）。Δ 为相对 SimpleCNN-80 的测试准确率变化。

模型	参数量	最佳 epoch	验证准确率	测试准确率	Macro-F1	Δ
SimpleCNN（30 ep）	1.17M	25	83.67%	79.85%	0.7936	−4.91
SimpleCNN（80 ep）	1.17M	75	87.66%	84.76%	0.8451	0.00
ResidualCNN	1.22M	65	88.02%	85.12%	0.8494	+0.36
ResidualCNN deep	2.69M	31	87.48%	85.48%	0.8527	+0.72
ResidualCNN + SE	1.23M	67	**89.11%**	**86.39%**	**0.8597**	+1.63

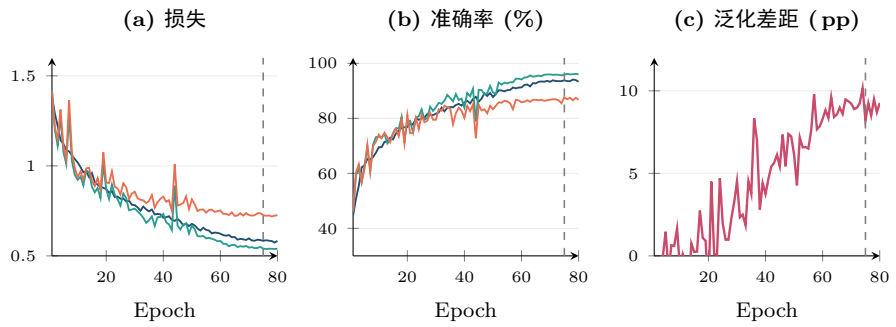


图 8: 80 epoch 从零训练曲线。蓝色为训练（增强），青色为训练（无增强），珊瑚色为验证；(c) 为无增强训练准确率与验证准确率之差。虚线为最佳验证 epoch（75）。差距在后期稳定在 8–9 pp，说明模型已较强地拟合训练分布。

4.2.2 残差连接与 SE 注意力

在参数预算基本不变时，结构改动的收益有限且不单调。残差连接只增加 44K 参数，把验证/测试准确率各提升约 0.36 pp，roses 的验证 F1 由 0.826 升到 0.844（表 7、图 9）。继续加深到 2.69M 参数（Residual-deep）没有提升验证集（87.48%），测试集虽略高（85.48%），但 roses/tulips 的双向混淆增加；当前数据规模下深度不是瓶颈，容量增加只带来更多方差。

SE 是唯一在验证与测试上同时明显正向的结构改动：只增加 0.87% 参数，验证准确率达到 89.11%、测试准确率达到 86.39%，比 ResidualCNN 分别提升 1.09 pp与 1.27 pp。验证集 roses/tulips 双向混淆由 21 降到 20，测试集仍有 25 个双向错误；通道注意力改善的是整体特征选择，而不是专门解决这一对难类。真正的突破来自迁移学习与更高分辨率。

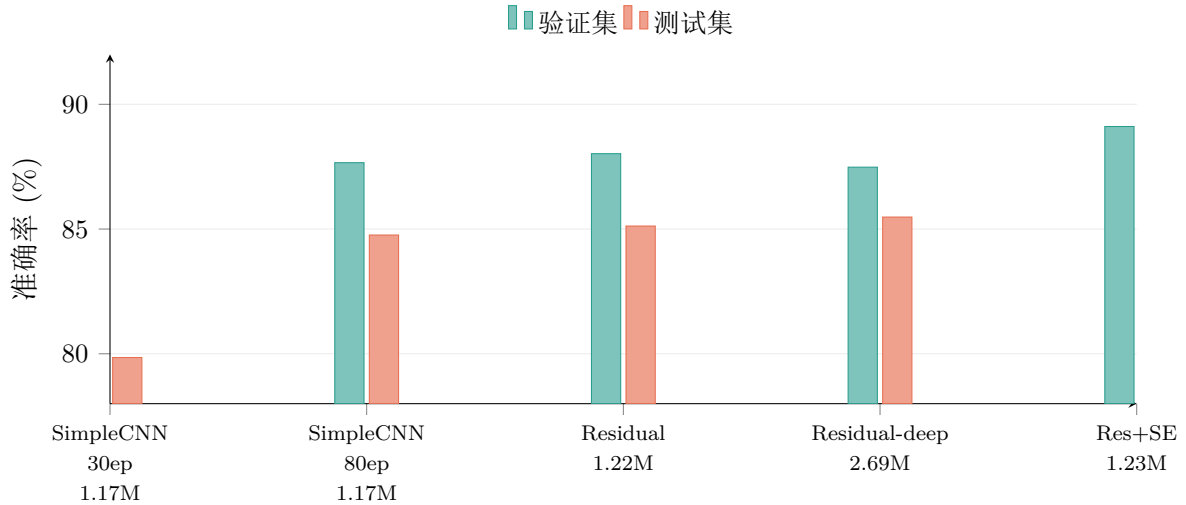


图 9: 从零训练结构消融。残差连接小幅提升；SE 在参数几乎不变的前提下带来最大增益；继续加深（Residual-deep）没有提升验证集。柱下为参数量。

4.3 迁移单模型

迁移学习是性能提升的主要来源（表 8、图 10）。从零最佳模型 86.39% 到 ConvNeXt-Base+EMA+TTA 的 96.91%，提升 10.52 pp；即使最小的 MobileNetV3-Small（1.52M 参数，仅比从零模型多 24%），8 轮就达到 92.56%，比从零最佳高 6.17 pp。EfficientNetV2-M 与 ConvNeXt-Base 在 5 轮内达到 96% 以上，训练曲线在 epoch 2–3 已越过 93%，预训练主干已具备可迁移的花卉纹理与形状表征。

迁移模型的训练集饱和速度也明显更快：所有模型在最佳 epoch 的无增强训练准确率都在 99.8% 左右，2.5k 张训练图在 1–2 轮内几乎被完全拟合。此时继续训练只会增加过拟合，迁移阶段因此限制在 5–20 轮，并用 EMA 与 early stopping 选择模型；从零模型需要 65–80 轮才收敛。

4.4 分辨率、EMA 与 TTA

提高输入分辨率首先改善的是难类，而不是总体准确率。ConvNeXt 的输入从 224 提到 256（短边 288）后，验证准确率从 95.10% 升到 95.83%，验证集 roses F1 从 0.898 升到 0.930，tulips F1 从 0.914 升到 0.934，roses↔tulips 双向混淆从 16 降到 10。更高分辨率主要帮助花瓣层次、边缘锯齿与花心结构，这些细节正是玫瑰与重瓣郁金香的区别。

单模型的原始测试准确率仍是 96.73%，没有超过 224 版本的 96.91%。只有 35% 的原始图像能原生支持 288 短边，其余样本被上采样，细节收益被稀释；测试集只有 551 张，0.2 pp的差异只对应 1 张图。稳定的收益体现在验证集的难类 F1 上，256 版本因此作为集成成员，而不是唯一部署模型（表 9）。图 11 比较了三个代表性模型的逐类 F1，迁移带来的提升主要集中在 roses 与 tulips。

EMA 与 TTA 的收益较小：ConvNeXt 从 96.73% 提升到 96.91%（+0.18 pp），EfficientNetV2-M 从 96.19% 提升到 96.73%（+0.54 pp）。表中 EMA+TTA 行的验证准确率只反映 EMA（验证不做 TTA），测试准确率包含翻转 TTA，两列不能直接相减来估计 TTA 的贡献。数据增强的单变量消融见附录 C。

表 8: 迁移学习结果（原始 551 张测试集）。EMA+TTA 行的验证准确率为 EMA 模型、不含 TTA；测试准确率含翻转 TTA。

模型	参数量	epochs	验证准确率	测试准确率	Macro-F1
MobileNetV3-Small	1.52M	8	92.56%	92.56%	0.9239
EfficientNetV2-M	52.86M	5	94.56%	96.19%	0.9615
ConvNeXt-Base	87.57M	5	94.92%	96.73%	0.9665
ConvNeXt-Base + EMA + TTA	87.57M	8	95.10%	**96.91%**	**0.9683**
EfficientNetV2-M + EMA + TTA	52.86M	10	94.01%	96.73%	0.9669
ConvNeXt-Base-256 + EMA + TTA	87.57M	6	**95.83%**	96.73%	0.9669

表 9: 分辨率与训练数据版本的对照。原始测试集为 551 张，清洗测试集为 544 张，二者不可逐项直接比较。

模型	训练/评测数据	输入	准确率	Macro-F1
ConvNeXt + EMA + TTA	原训练集 / 原测试集	224	**96.91%**	0.9683
ConvNeXt + EMA + TTA	原训练集 / 原测试集	256	96.73%	0.9669
ConvNeXt + EMA + TTA	原训练集 / 清洗测试集	256	96.88%	0.9680
ConvNeXt + EMA + TTA	清洗训练集 / 清洗测试集	256	96.69%	0.9661

4.5 清洗重训（补充实验）

清洗没有在重训中转化为准确率提升。清洗后的数据为 2,527 / 538 / 544；用同样的 ConvNeXt-256 配置在清洗训练集上重训 20 轮，最佳验证准确率达到 **97.03%**，但清洗测试准确

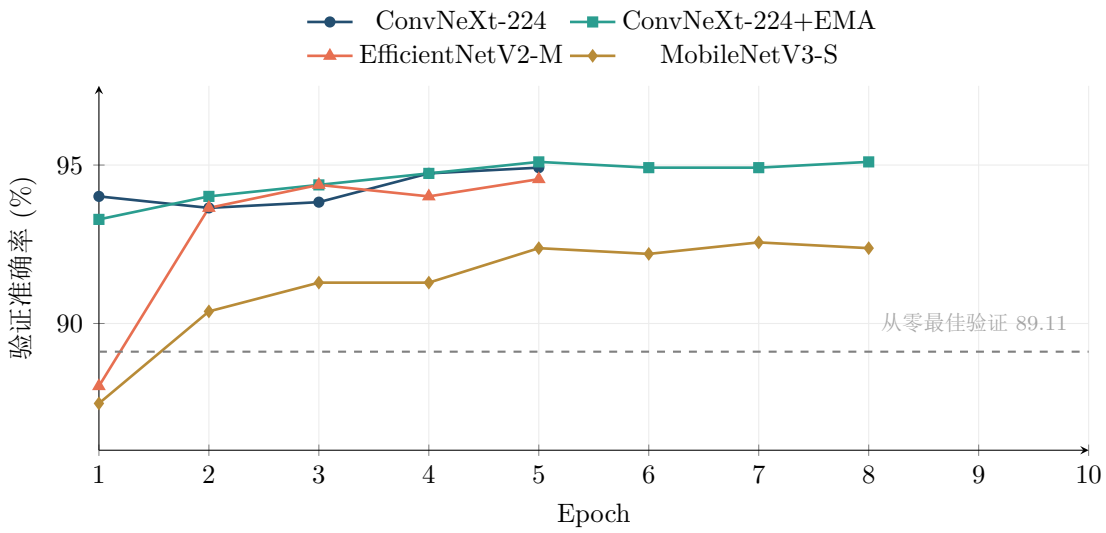


图 10: 迁移学习的验证准确率随 epoch 变化。所有曲线从第 1 轮起就高于从零训练的 80 轮最佳（89.11%）；MobileNetV3-Small 用 1.52M 参数在 8 轮内达到 92.6%，说明预训练表征比模型容量更关键。

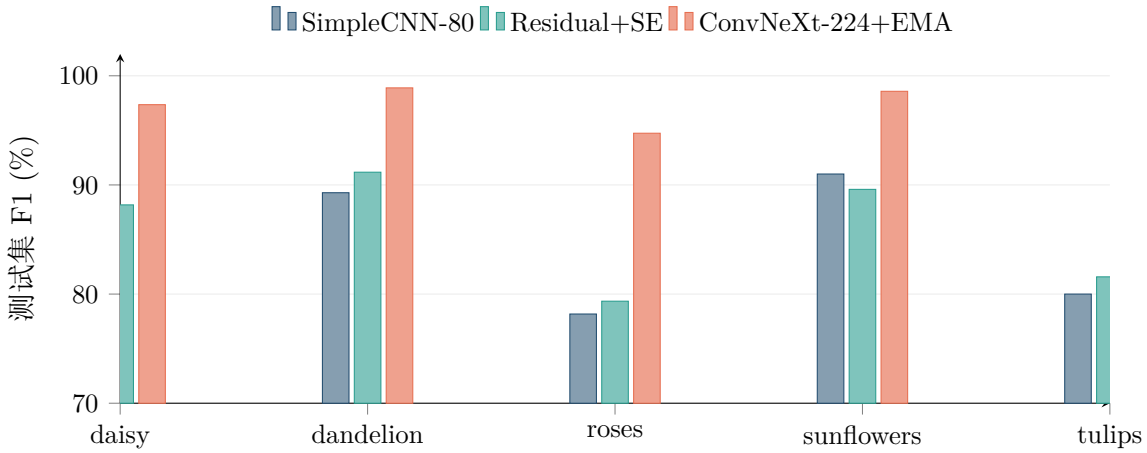


图 11: 三个代表性模型在原始测试集上的逐类 F1。迁移学习把 roses 与 tulips 的 F1 分别从 79.3/81.6 提升到 94.7/94.6，提升幅度（约 15 pp）远大于 daisy 与 sunflowers（约 7–9 pp），说明预训练表征主要补足了“花型与花瓣结构”这一最难维度。

率为 96.69%，比未重训的原模型在同一测试集上的 96.88% 低 0.19 pp，即 1 张图（表 10）。训练在第 1 轮取得最佳验证，随后 5 轮不升并早停，模型在 1 个 epoch 内已拟合完清洗训练集。

原因有三点。清洗只移除 37 张训练图（1.4%），对 2.5k 规模的训练集几乎没有信息量影响；审计仍保留 7 张物种存疑样本，测试集也可能有未发现的错标；清洗后的验证集少 13 张，early stopping 的信号更抖，第 1 轮即最佳的结果难以复现。迁移模型在原始数据上的训练准确率已达 99.8%，错误主要来自任务边界，而不是被删除的无关图。清洗的收益因此小于重训方差；它的价值在于让 97.43% 的评测口径更可信，而不是提高这个数字。

表 10: 标签清洗与重训结果。所有数值均为同一清洗测试集（544 张）或原始测试集（551 张）上的结果，最后一列为错误数。

配置	训练/评测数据	准确率	Macro-F1	错误数
原 ConvNeXt-256（不重训）	原训练集 / 清洗测试集	**96.88%**	**0.9680**	17/544
清洗重训 ConvNeXt-256	清洗训练集 / 清洗测试集	96.69%	0.9661	18/544
原 ConvNeXt-256	原训练集 / 原测试集	96.73%	0.9669	18/551
最终两模型集成	原训练集 / 清洗测试集	**97.43%**	**0.9737**	**14/544**

4.6 错误分析

残余错误并不均匀分布（图 12）。最终集成的 14 个错误中，roses↔tulips 共 7 个（3+4），占 50%；sunflowers→dandelion 2 个，tulips→daisy 2 个，其余 3 个为单例。daisy、dandelion、sunflowers 的错误多是黄色花心、白色花瓣与绿色背景之间的局部混淆，属于边缘案例；roses 与 tulips 的错误则是系统性的花型重叠。后者靠增加数据量或提高分辨率只能缓慢改善，进一步突破需要部件级监督（花瓣分割、花心定位）或更强的细粒度目标函数。

部分错误也可能来自标签边界。审计保留了 7 张物种存疑样本，测试集中也可能存在看起来像玫瑰的重瓣郁金香；未逐张复核最终 14 个错误之前，不对其归属下结论。

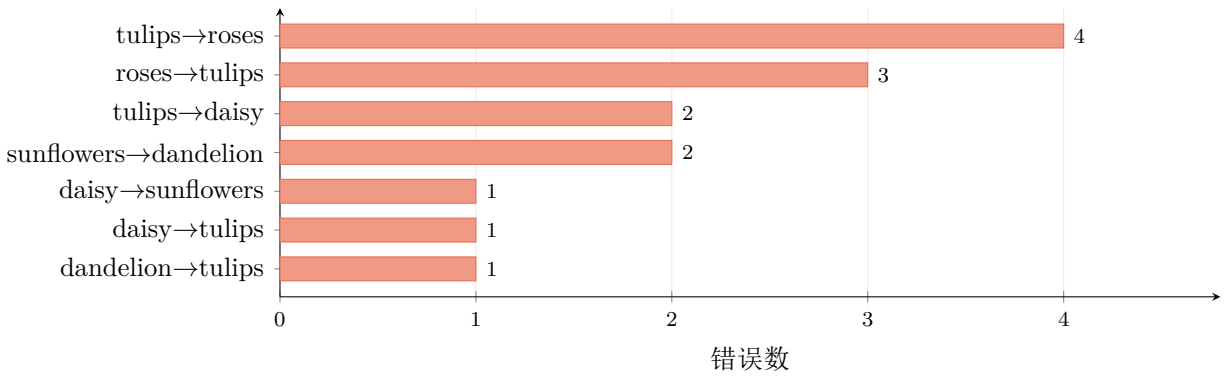


图 12: 最终集成的错误分解（共 14 个/544）。roses↔tulips 占 7 个，是唯一具有系统性的混淆对；其余错误均为 1–2 个的边缘案例。

4.7 讨论：增益、代价与局限

4.7.1 成本与精度的关系

预训练同时改善准确率与训练效率：从零最佳模型训练约 30 分钟才到 86.39%，ConvNeXt 用 3–6 分钟就到 96.7% 以上。容量与精度并不单调：MobileNetV3-Small（1.52M）达到 92.56%，已超

过所有从零模型；EfficientNetV2-M（52.86M）与 ConvNeXt（87.57M）只差约 0.5 pp。集成的边际成本较高：双模型集成约 140M 参数、4 次前向，换来约 0.5 pp；端侧部署更适合 MobileNetV3-Small（表 11、图 13）。

表 11： 成本—精度对照。训练时间为各 epoch 的累计墙钟时间（单卡 RTX 5090 Laptop）；测试准确率为原始测试集（551 张），集成为清洗测试集（544 张）并标注。

模型	参数量	训练时间	测试准确率	推理前向次数
SimpleCNN-80	1.17M	27.9 min	84.76%	1
ResidualCNN+SE	1.23M	30.5 min	86.39%	1
MobileNetV3-Small	1.52M	3.8 min	92.56%	1
EfficientNetV2-M	52.86M	3.1 min	96.19%	1
ConvNeXt-Base-224	87.57M	3.1 min	96.73%	1
ConvNeXt-Base-224+EMA	87.57M	5.5 min	96.91%	2
ConvNeXt-Base-256	87.57M	4.0 min	96.73%	2
双模型集成（清洗测试集）	140.43M	7.1 min	**97.43%**	4

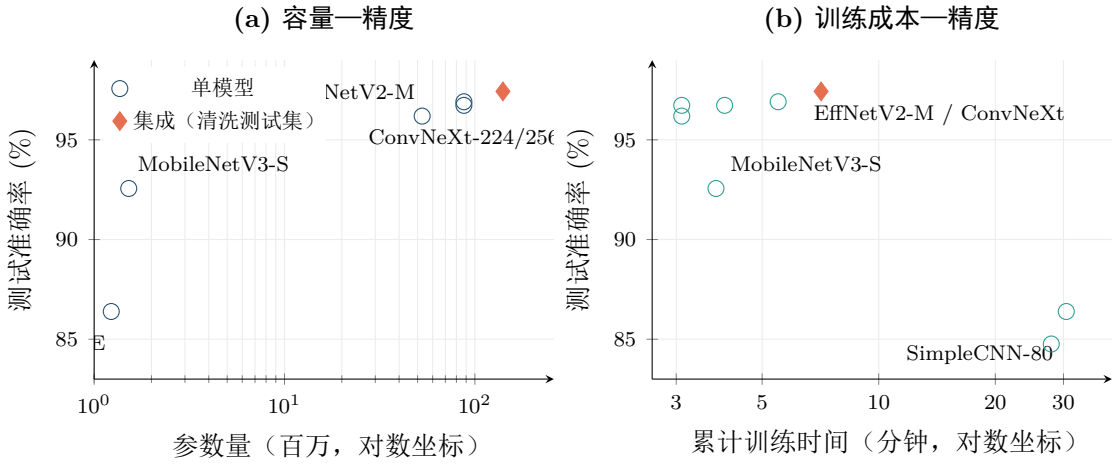


图 13： 成本—精度权衡。(a) 参数量与测试准确率：迁移模型把 Pareto 前沿整体上移，MobileNetV3-Small 以 1.52M 参数达到 92.56%。(b) 累计训练时间与准确率：从零模型训练 30 分钟仍低于 87%，而迁移模型 3–6 分钟即超过 96%。集成点（橙色菱形）为清洗测试集结果，其余为原始测试集。

4.7.2 性能增益的来源

各阶段的增益量级差异明显：训练长度带来约 5 pp，结构与注意力约 2 pp，预训练约 10 pp，集成约 0.5 pp。不同阶段的训练数据、增强与选型略有差异，这些增量不能严格相加，但量级足够清楚：预训练是主要来源，结构与集成只提供边际收益。继续加深网络没有效果，因为在 2.5k 训练样本上，容量不是约束，可迁移的先验知识才是。

4.7.3 标签噪声与任务难度

标签噪声不是当前的主要瓶颈。迁移模型在原始数据上的训练准确率已达 99.8%，说明它能拟合带噪训练集；清洗后的重训没有提高测试准确率，错误集中在 roses/tulips 的视觉重叠。清洗的作用是让评测口径更干净，而不是提供新的可学习信号。当前限制更可能来自任务可分性与样本规模：数据只有 3,670 张图、5 个类别，且类别边界本身不是物种级定义。

4.7.4 统计不确定性与选择偏差

本文报告的是单次运行的点估计。以 97.43%、$n = 544$ 为例，二项标准误约 0.68 pp，95% Wilson 区间为 $[95.7\%, 98.5\%]$。97.43% 与 96.88% 相差 0.55 pp，约 3 张图，未做配对检验前只能视为方向一致的改善；96.73% 与 96.91% 相差 0.18 pp，约 1 张图，完全在噪声范围内，不能据此断言 224 优于 256。本文在同一测试集上比较了约 20 个配置，存在选择偏差；模型选择主要依据验证集，但小幅差异仍需打折看待。更严格的做法是固定超参数后用 3–5 个随机种子重训、报告均值与标准差，或做 5 折交叉验证，并对关键比较做 McNemar 检验；本文因算力与时间限制未完成这些，属于主要方法学局限。

4.7.5 局限

本文的结论受三方面限制。数据只有 3,670 张、5 个类别，远小于 Flowers-102 等基准；图像来自 Flickr，许可与拍摄意图不受控，结论不应外推到更大规模或不同域的数据。结果均为 seed 42 的单次运行，Mixup 与 256 重训已显示选型方差不可忽略；更严格的比较需要多种子或交叉验证。类别边界也不是物种级定义：“roses”包含大量栽培品种，“tulips”包含单瓣、重瓣与鹦鹉型，97.4% 是该标注体系下的近似上限。此外，本文没有做 Grad-CAM[15] 或部件标注，无法定量判断模型是否依赖背景；也没有评估置信度校准、拒识与推理延迟，这些是部署前需要补做的分析。

5 结论

最终方案在 544 张清洗测试集上达到 97.43% 准确率与 0.9737 Macro-F1，错误 14 个；方案中的 ConvNeXt-256 单模型为 96.88%，最佳单模型 ConvNeXt-224 为 96.91%。集成相对最佳单模型提升 0.52 pp，错误数从 17 降到 14。收益来自两个分支的误差互补：ConvNeXt 偏向形状与全局结构，EfficientNetV2-M 偏向多尺度纹理，二者在不同分辨率下训练。代价是双模型推理：约 140M 参数、4 次前向，训练与评估成本约为单模型的两倍。

剩余错误集中在 roses↔tulips（14 个中 7 个），部分可能是标签边界；97.43% 只适用于当前标注版本与测试集。进一步改善需要更多数据、部件级监督或更强的细粒度目标函数。数据审计与去重划分应在结构选择之前完成；在类似的小规模花卉数据上，预训练主干仍是性价比较高的起点。

参考文献

[1] A. Krizhevsky, I. Sutskever, G. E. Hinton. ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems (NIPS)*, 2012: 1097–1105.

[2] K. He, X. Zhang, S. Ren, J. Sun. Deep residual learning for image recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016: 770–778. DOI: 10.1109/CVPR.2016.90.

[3] J. Hu, L. Shen, G. Sun. Squeeze-and-excitation networks. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018: 7132–7141. DOI: 10.1109/CVPR.2018.00745.

[4] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, S. Xie. A ConvNet for the 2020s. *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022: 11976–11986. DOI: 10.1109/CVPR52688.2022.01167.

[5] M. Tan, Q. V. Le. EfficientNetV2: Smaller models and faster training. *International Conference on Machine Learning (ICML)*, PMLR 139, 2021: 10096–10106.

[6] A. Howard, M. Sandler, G. Chu, et al. Searching for MobileNetV3. *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019: 1314–1324. DOI: 10.1109/ICCV.2019.00140.

[7] M.-E. Nilsback, A. Zisserman. Automated flower classification over a large number of classes. *Indian Conference on Computer Vision, Graphics and Image Processing (ICVGIP)*, 2008: 722–729.

[8] T.-Y. Lin, A. RoyChowdhury, S. Maji. Bilinear CNN models for fine-grained visual recognition. *IEEE International Conference on Computer Vision (ICCV)*, 2015: 1449–1457.

[9] X.-S. Wei, Y.-Z. Song, O. Mac Aodha, J. Wu, Y. Peng, J. Tang, J. Yang, S. Belongie. Fine-grained image analysis with deep learning: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(12), 2022. DOI: 10.1109/TPAMI.2021.3126648.

[10] H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz. mixup: Beyond empirical risk minimization. *International Conference on Learning Representations (ICLR)*, 2018.

[11] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, Z. Wojna. Rethinking the Inception architecture for computer vision. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016: 2818–2826. DOI: 10.1109/CVPR.2016.308.

[12] A. Tarvainen, H. Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. *Advances in Neural Information Processing Systems (NIPS)*, 2017: 6125–6134.

[13] T. G. Dietterich. Ensemble methods in machine learning. *Multiple Classifier Systems (MCS)*, LNCS 1857, 2000: 1–15. DOI: 10.1007/3-540-45014-9_1.

[14] C. G. Northcutt, L. Jiang, I. L. Chuang. Confident learning: Estimating uncertainty in dataset labels. *Journal of Artificial Intelligence Research*, 70, 2021. DOI: 10.1613/jair.1.12171.

[15] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *IEEE International Conference on Computer Vision (ICCV)*, 2017: 618–626. DOI: 10.1109/ICCV.2017.74.

[16] C. Shorten, T. M. Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6:60, 2019. DOI: 10.1186/s40537-019-0197-0.

A 实验配置与超参数

所有实验使用统一的随机种子 42、分层划分与确定性评估变换，主要配置如下。

- **从零训练**：AdamW（学习率 10^{-3}，权重衰减 10^{-4}），余弦退火，batch size 32，最多 80 个 epoch，early stopping patience 15，标签平滑 0.1，混合精度；输入 224，训练增强为随机缩放裁剪（0.65–1.0）、水平翻转与颜色抖动，最终配置关闭色相扰动。
- **迁移学习**：ImageNet 预训练主干，替换 5 类分类头后全参数微调；学习率 10^{-4} 至 2×10^{-5}，权重衰减 0.01，训练 5–20 个 epoch；EMA 衰减 0.995，测试时使用水平翻转 TTA。
- **输入分辨率**：224 模型采用短边缩放 256 后中心裁剪 224；256 模型采用短边缩放 288 后中心裁剪 256。
- **集成**：对各成员的概率输出做等权平均，成员与组合在验证集上选择，测试集只报告被选中的组合。
- **评价**：准确率、Macro-F1、逐类 precision/recall/F1 与混淆矩阵；同时报告二项标准误与 Wilson 区间。

B 完整实验结果

表 12 汇总了本文引用的全部训练运行。表中的训练轮数为实际运行轮数（含 early stopping），不是配置上限；带“清洗”标记的运行在清洗测试集上评估。

表 12: 完整实验登记表。所有指标来自训练日志与评估记录。

实验	架构	输入	轮数	验证准确率	测试准确率	Macro-F1
基线-30	SimpleCNN	224	30	83.67%	79.85%	0.7936
基线-80	SimpleCNN	224	80	87.66%	84.76%	0.8451
旋转增强	SimpleCNN	224	80	87.11%	85.12%	0.8488
裁剪增强	SimpleCNN	224	80	86.93%	84.76%	0.8456
去色相扰动	SimpleCNN	224	80	87.84%	85.66%	0.8525
Mixup	SimpleCNN	224	80	88.75%	83.30%	0.8297
残差	ResidualCNN	224	80	88.02%	85.12%	0.8494
残差-加深	Residual-deep	224	46	87.48%	85.48%	0.8527
残差 +SE	Residual+SE	224	80	89.11%	86.39%	0.8597
MobileNetV3-S	MobileNetV3-S	224	8	92.56%	92.56%	0.9239
ConvNeXt-224	ConvNeXt-B	224	5	94.92%	96.73%	0.9665
ConvNeXt-224+EMA	ConvNeXt-B	224	8	95.10%	96.91%	0.9683
EfficientNetV2-M	EffNetV2-M	224	5	94.56%	96.19%	0.9615
EfficientNetV2-M+EMA	EffNetV2-M	224	10	94.01%	96.73%	0.9669
ConvNeXt-256	ConvNeXt-B	256	6	95.83%	96.73%	0.9669
ConvNeXt-256（清洗重训）	ConvNeXt-B	256	6	97.03%	96.69%†	0.9661
ConvNeXt-256（原模型/清洗测试）	ConvNeXt-B	256	–	95.83%	96.88%†	0.9680

† 在 544 张清洗测试集上评估；其余为 551 张原始测试集。

C 增强消融

增强的效果取决于它是否破坏类别定义。单变量消融显示，旋转、裁剪与色相扰动的收益并不一致（表 13、图 14）。旋转 ±20° 把测试准确率提高 0.36 pp，但验证集下降 0.55 pp，tulips F1 从 0.831 降到 0.817，属于测试集波动而非稳定收益。把随机裁剪下限从 0.65 提高到 0.8 更激进地放大局部，测试没有提升，roses F1 从 0.826 掉到 0.786；过度裁剪切掉了花瓣层次与花型结构，伤害细粒度判别。

关闭色相扰动（hue=0）是唯一在验证、测试、roses F1 与 tulips F1 上同时正向的改动，测试达到 85.66%，Macro-F1 0.8525。颜色与类别高度相关：hue 抖动幅度 0.05 已足以把黄色蒲公英推向橙色、把红色玫瑰推向品红，破坏类别定义。颜色既是捷径，也是信号；在细粒度任务上，过强的颜色增强会同时删掉二者。最终配置关闭色相扰动。

Mixup（$\alpha = 0.2$，标签平滑 0.05）把 roses/tulips 双向错误降到 17（所有消融中最少），并把泛化差距从 8.2 pp降到 5.6 pp，但最佳验证模型的测试准确率只有 83.30%，最后一轮为 84.57%。单次运行的模型选择噪声不可忽略，更好的正则化也不一定在每一个测试点上兑现。该结果来自单次运行，只作为现象报告。

表 13： 数据增强单变量消融（SimpleCNN，80 epochs，原始测试集）。roses/tulips F1 与双向错误来自验证集；双向错误为 roses→tulips 加 tulips→roses。

设置	验证准确率	测试准确率	Macro-F1	roses F1	tulips F1	双向错误
baseline	87.66%	84.76%	0.8451	0.826	0.831	21
旋转 ±20°	87.11%	85.12%	0.8488	0.836	0.817	20
裁剪 0.8–1.0	86.93%	84.76%	0.8456	0.786	0.835	21
hue=0	**87.84%**	**85.66%**	**0.8525**	**0.847**	**0.849**	21
Mixup $\alpha = 0.2$	88.75%	83.30%	0.8297	0.842	0.854	**17**

注：Mixup 为单次探索性运行；其最后一轮测试准确率为 84.57%，高于最佳验证模型的 83.30%，体现了选型噪声。

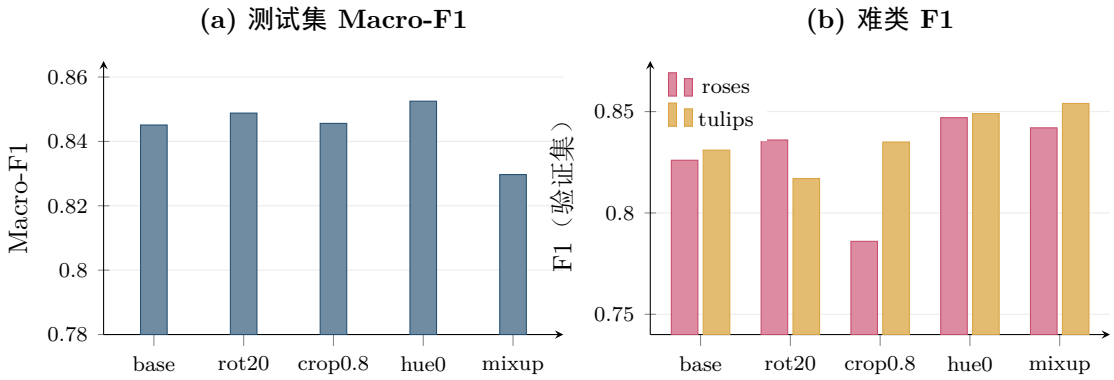


图 14： 增强消融。(a) 测试集 Macro-F1；(b) roses/tulips 的验证集 F1。hue=0 在两幅子图中都最稳定；crop 0.8 明显伤害 roses；Mixup 改善难类 F1 与双向混淆，但最佳验证模型的测试 Macro-F1 反而下降。