设计还是迁移？
小规模花卉分类中网络设计与预训练集成的再审视

To Design or to Transfer? Revisiting Architecture Search vs. Pretrained Ensembles for Flower Recognition

摘要

本文旨在为训练样本有限的花卉数据集设计分类模型，使其能够准确识别五类花卉。实验使用包含 3,670 张图像的数据集，其中玫瑰与郁金香的部分样本外观相近。以自建卷积神经网络为基线，比较了网络结构、数据增强与 ImageNet 预训练模型的微调方案。在原测试集上，表现最好的自建模型和预训练单模型的准确率分别为 86.39% 和 96.91%。根据验证集结果，选用输入尺寸不同的 ConvNeXt-Base 和 EfficientNetV2-M，对两者预测的类别概率取等权平均，集成准确率达到 97.46%。该模型在清洗后的 544 张测试图像上取得 97.43% 的准确率和 0.9737 的宏平均 F1。模型判错的 14 张图像中，有 7 张发生在玫瑰与郁金香之间，这两类仍是五类花卉中最难区分的一对。

关键词：细粒度图像分类；迁移学习；概率集成；小规模数据集；标签清洗

Abstract. This study aims to design a classifier that accurately identifies five flower classes with limited training data. The dataset contains 3,670 images, including roses and tulips with similar appearances. Starting from a custom convolutional neural network baseline, we compared network architectures, data augmentation settings, and models fine-tuned from ImageNet weights. On the original test set, the best custom model and the best fine-tuned single model achieved 86.39% and 96.91% accuracy, respectively. Based on validation results, we selected ConvNeXt-Base and EfficientNetV2-M with different input sizes and averaged their class probabilities with equal weights. The ensemble achieved 97.46% accuracy on the original test set and 97.43% accuracy with a macro F1 score of 0.9737 on the cleaned test set of 544 images. Confusion between roses and tulips accounted for seven of the 14 remaining errors, making them the hardest pair to distinguish.

Keywords: Fine-Grained Image Classification, Transfer Learning, Probability Averaging, Small Datasets, Label Cleaning

1 引言

1.1 任务背景与研究问题

花卉识别属于细粒度图像分类任务。不同类别可能共享相似的颜色和花瓣形态，同一类别的图像又会因花朵状态、拍摄距离、光照与背景而呈现较大差异。本文使用的五类花卉数据集包含 3,670 张图像，原始训练划分约有 2.5k 张；其中 roses 与 tulips 的花型和花瓣层次相近，是较易混淆的类别。小规模数据和类间视觉相似性使模型既要学习有区分力的花朵表征，也要避免过度适应有限训练样本。

针对细粒度识别，已有研究探索了部件定位与双线性特征表示，以增强局部判别信息 [8, 9]。迁移学习利用大规模数据集预训练的视觉表征，再在目标数据上微调，已成为小样本图像分类的重要路线 [2, 4, 5]。此外，数据增强、指数移动平均、测试时增强和模型集成等策略也常用于改善泛化与预测稳定性 [10, 11, 12, 13]。花卉数据集研究指出，类别边界和拍摄条件会影响识别难度 [7]；标签质量研究则提出依据模型不确定性筛查可疑标注，并通过额外证据进行核查 [14]。

已有研究为细粒度识别提供了多种可行的网络结构与训练方法。本文以构建适用于该五类花卉数据集的分类模型为目标，围绕有限样本下的表征学习开展模型设计与实验：先构建卷积网络基线并考察残差连接和 SE 注意力，再引入预训练主干，进一步探索输入分辨率与模型集成。数据去重和标签复核用于保证训练划分与结果分析的可靠性，最终据此确定适合本任务的模型方案。

1.2 研究目标与贡献

本文围绕上述目标开展模型构建与验证，主要工作如下。第一，针对小样本条件设计并比较随机初始化的卷积网络，分析残差连接与 SE 注意力对模型表现的影响。第二，采用 ImageNet 预训练主干进行迁移学习，并进一步比较输入分辨率和概率集成方案，形成最终分类模型。第三，根据模型错误筛查高风险样本，结合原图和可查来源进行人工复核，排除 57 张无关或错标图像，并在清洗后的测试集上重新评估模型。

2 数据集与数据处理

2.1 数据概况

数据集包含 5 个类别、3,670 张 JPEG 图像，全部为 RGB，无损坏文件。表 1 汇总了类别规模与基本视觉统计。dandelion 最多（898 张，24.5%），daisy 最少（633 张，17.2%），最大与最小类别的样本数之比约为 1.42。数据划分采用分层抽样，使各子集中五类花卉的比例接近整体分布。

表 1: 数据集类别分布与视觉统计。

类别	图像数	占比	平均尺寸	宽高比	短边 ≥224	亮度	饱和度
daisy	633	17.2%	359 × 271	1.31	72.5%	0.48	0.42
dandelion	898	24.5%	367 × 274	1.32	77.5%	0.47	0.48
roses	641	17.5%	364 × 275	1.31	79.1%	0.53	0.47
sunflowers	699	19.0%	360 × 270	1.32	73.4%	0.56	0.59
tulips	799	21.8%	372 × 269	1.37	65.0%	0.54	0.51
合计	3,670	100%	365 × 272	1.33	73.4%	0.52	0.49

图 1 的两个统计直接影响输入设计。左图显示分层划分后的类别比例与原始分布一致；右图给出短边累积分布：73.4% 的图像短边不小于 224，35.0% 不小于 288。把输入分辨率从 224[1] 提到 256（短边缩放 288）时，约 65% 的样本仍要上采样[2]，原生细节有限。这一约束解释了后文 256 输入只在 roses/tulips 等难类上带来小幅改善，而不改变总体测试准确率。

[1]本文所称输入分辨率 224 和 256 分别指 224 × 224 和 256 × 256 像素图像。

[2]上采样是将原图放大到目标像素尺寸的插值操作。

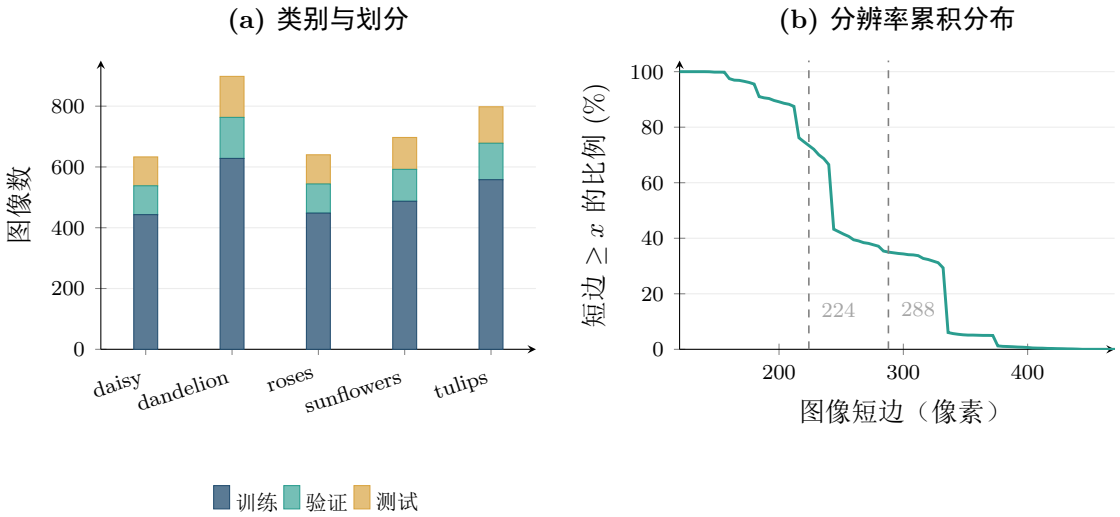


图 1: 数据总览。(a) 分层划分后的类别构成；(b) 图像短边的累积分布，虚线标出 224 与 288 两个关键阈值。

2.2 颜色与构图偏置

各类别的色相分布有所不同：dandelion 与 sunflowers 多为黄橙色，roses 多为红色或品红色，daisy 与 tulips 的颜色分布较分散。颜色有助于区分花卉类别，但模型也可能利用背景颜色和构图等信息。为此，训练阶段采用颜色抖动和随机缩放裁剪，并在附录 C 比较颜色扰动对分类结果的影响。

2.3 重复检测与簇级划分

重复样本是小型数据集上最常见的隐性泄漏源：同一张图或同一场景的轻微变体若同时出现在训练集与测试集，指标会被系统性高估。本文用两级指纹识别重复图像。完全重复根据文件 MD5 判定；近重复使用 64 位 dHash：将图像转为 9×8 灰度图，比较水平相邻像素得到指纹 h，两张图像的汉明距离为

$$d_H(h_i, h_j) = \mathrm{popcount}(h_i \oplus h_j). \tag{1}$$

当 $d_H \le 4$ 时用并查集合并为同一簇，划分时以簇为最小单位，保证同一簇只进入训练/验证/测试集之一。

原始数据中检出 3 组完全重复（6 张）与 17 对近重复（34 张，占 0.9%），其中 1 组完全重复跨类别冲突（同一张图同时出现在 roses 与 tulips，无法确定唯一标签）。处理策略是：跨类冲突整组剔除（2 张），同类完全重复每组保留一张（剔除 2 张），近重复簇整体分入同一划分。最终使用 3,666 张，采用随机种子 42 按类别分层划分为 2,564 / 551 / 551（约 70% / 15% / 15%）。

2.4 预处理与数据增强

所有图像统一转为 RGB，并按 ImageNet 统计量归一化：

$$\hat{x}_c = \frac{x_c - \mu_c}{\sigma_c}, \qquad \mu = (0.485, 0.456, 0.406), \quad \sigma = (0.229, 0.224, 0.225). \tag{2}$$

224 模型采用 Resize(256) $\rightarrow$ CenterCrop(224)；256 模型采用 Resize(288) $\rightarrow$ CenterCrop(256)。训练增强包括随机缩放裁剪（面积比例 0.65–1.0，宽高比 0.8–1.25）、水平翻转与颜色抖动（亮度/对

表 2: 去重后数据集的分层划分（共 3,666 张）。

类别	训练集	验证集	测试集	合计
daisy	443	95	95	633
dandelion	628	135	135	898
roses	448	96	96	640
sunflowers	487	105	105	697
tulips	558	120	120	798
合计	2,564	551	551	3,666

比度/饱和度 0.2，色相 0.05），关于图像增强的系统综述可参见 [16]。验证与测试阶段只进行缩放和中心裁剪[3]；附录 A 的图 11 展示同一张图经过四种变换后的结果。

2.5 评价指标

本文根据验证集表现选择训练轮数、输入分辨率和集成成员，并使用准确率、Macro-F1、各类别 F1 及混淆矩阵评价分类结果。对 N 个样本，准确率与宏平均 F1 为

$$\mathrm{Acc} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}[\hat{y}_i = y_i], \tag{3}$$

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = \frac{2P_cR_c}{P_c + R_c}, \tag{4}$$

$$\text{Macro-F1} = \frac{1}{K}\sum_{c=1}^{K} F1_c. \tag{5}$$

同时记录混淆矩阵、各类别 F1 与 roses/tulips 双向混淆数。由于测试集只有 544–551 张，准确率的二项标准误为

$$\mathrm{SE}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{N}} \approx 0.7\,\mathrm{pp} \quad (\hat{p} \approx 0.97,\ N \approx 550), \tag{6}$$

对应的 95% Wilson 区间约为 $[95.7\%, 98.5\%]$。0.2–0.5 pp的差异通常只对应 1–3 张图。

3 CNN 基线与模型改进

3.1 CNN 基线结构

本文先构建轻量卷积神经网络（CNN）作为基线，模型权重采用随机初始化。输入为 224×224 的 RGB 图像，经过四个卷积块提取由浅入深的视觉特征。每个卷积块包含两层 3×3 卷积，每层后接批归一化和 ReLU 激活，再通过最大池化将特征图宽高减半；通道数依次增加到 32、64、128 和 256。最后，模型对空间维度做全局平均池化，经 Dropout 后由全连接层输出五类得分。图 2 展示该基线结构。

3.2 训练

CNN 基线采用 AdamW（学习率 10^{-3}、权重衰减 10^{-4}）、每批 32 张图像、余弦退火和标签平滑 0.1。完整训练配置见附录 B。SimpleCNN 最初训练上限设为 30 轮，最佳检查点位于第 25

[3]中心裁剪固定裁剪区域；同一图像重复处理时会得到相同的输入图像。

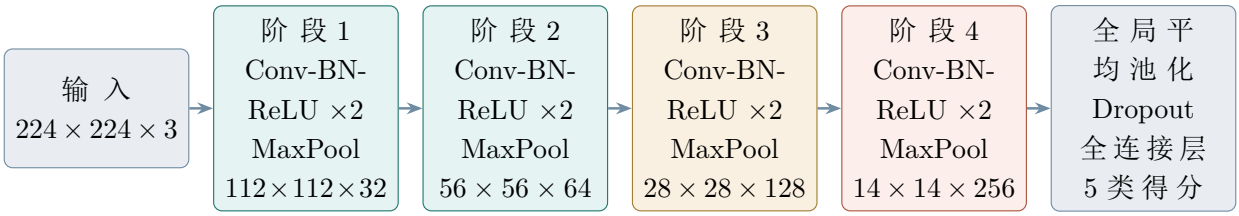


图 2: SimpleCNN 的结构。每个阶段由两层 3×3 卷积、批归一化和 ReLU 组成，并以最大池化将特征图宽高减半。

轮，验证准确率为 83.67%，测试准确率为 79.85%。随后将上限延长至 80 轮，最佳检查点移至第 75 轮，验证准确率和测试准确率分别达到 87.66% 和 84.76%（表 3）。

图 3 记录了 SimpleCNN 训练 80 轮的过程。蓝线表示训练时在随机增强图像上计算的损失和准确率，青线表示对同一训练集采用与验证集、测试集相同的预处理后得到的结果，珊瑚线表示验证集结果。图 3(c) 以青线和珊瑚线的准确率之差衡量泛化差距，两组图像采用相同的预处理方式。

图 3(a)(b) 显示，训练后期训练损失继续下降，训练准确率仍在上升，验证曲线则趋于平稳。图 3(c) 中的差距从第 20 轮后开始扩大。第 75 轮时，训练集和验证集准确率分别为 95.87% 和 87.66%，相差 8.21 pp。训练后期对训练样本的进一步拟合只带来了有限的验证集改善。

表 3: 模型对比（Δ 为相对 SimpleCNN-80 测试准确率的变化）。

模型	参数量	最佳 epoch	验证准确率	测试准确率	Macro-F1	Δ
SimpleCNN（30 ep）	1.17M	25	83.67%	79.85%	0.7936	−4.91
SimpleCNN（80 ep）	1.17M	75	87.66%	84.76%	0.8451	0.00
ResidualCNN	1.22M	65	88.02%	85.12%	0.8494	+0.36
ResidualCNN deep	2.69M	31	87.48%	85.48%	0.8527	+0.72
ResidualCNN + SE	1.23M	67	**89.11%**	**86.39%**	**0.8597**	+1.63

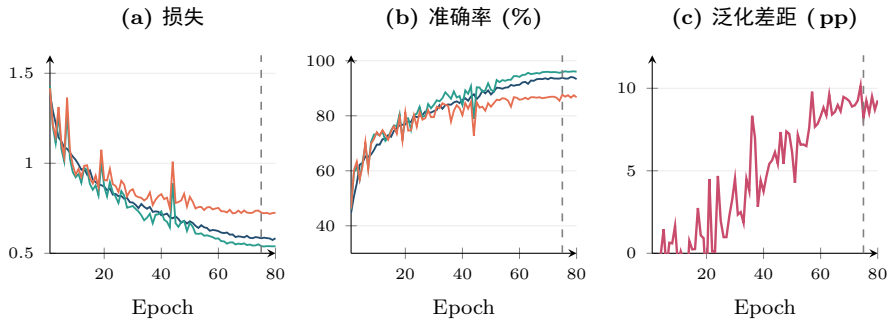


图 3: SimpleCNN 的 80 轮训练曲线。蓝色为训练（增强），青色为训练（无增强），珊瑚色为验证；(c) 为无增强训练准确率与验证准确率之差。虚线为最佳验证 epoch（75）。差距在后期稳定在 8–9 pp，说明模型已较强地拟合训练分布。

3.3 残差 CNN 的设计与评估

第 3.2 节延长了 SimpleCNN 的训练时间，验证准确率在训练后期趋于平稳。本节以训练 80 轮的 SimpleCNN 为基线，比较三种网络结构改动。如图 4 所示，ResidualCNN 在各卷积块中加入捷径，沿用基线的四阶段通道数与下采样安排。在此基础上，Residual-deep 在第三、第四阶段

各增设一个残差块，ResidualCNN+SE 则在这两个阶段的残差分支中加入 SE 通道注意力。

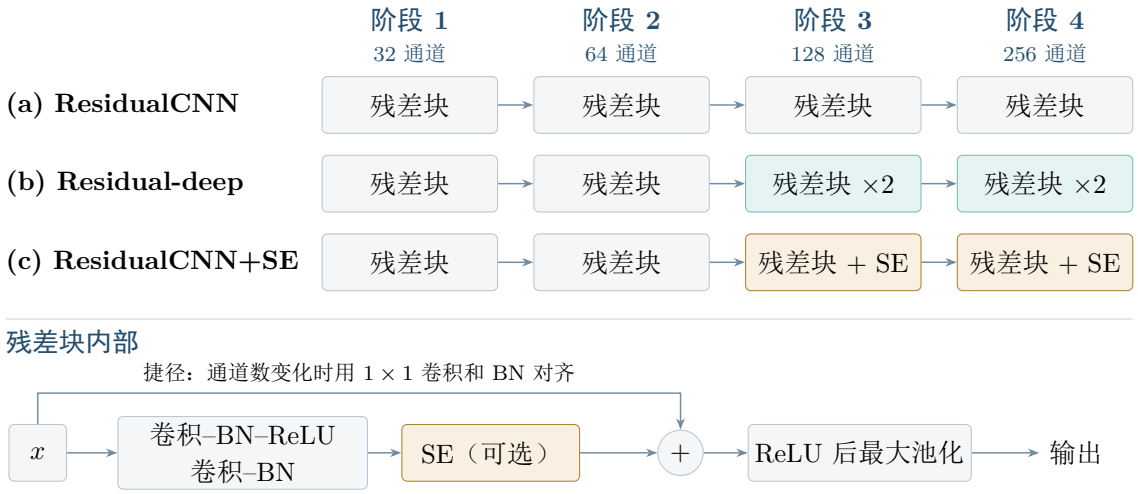


图 4: 三种 CNN 变体的阶段结构与残差块。

图 5 对比了各模型在最佳验证轮次的验证集与测试集准确率。每组柱形下方列出模型名称、实际训练轮数 / 验证集最佳轮次和参数量。

ResidualCNN 比 SimpleCNN-80 增加约 44K 参数，验证和测试准确率均提高 0.36 pp，roses 的验证 F1 从 0.826 升至 0.844。

Residual-deep 的最佳检查点出现在第 31 轮。此后连续 15 轮未刷新最佳验证结果，触发提前停止，实际训练 46 轮。该模型的参数量增至 2.69M。与 ResidualCNN 相比，验证准确率降低 0.54 pp，测试准确率提高 0.36 pp，roses 被误判为 tulips 或 tulips 被误判为 roses 的总次数也有所增加。

ResidualCNN+SE 比 ResidualCNN 增加 0.87% 的参数，验证和测试准确率分别达到 89.11% 和 86.39%，是图 5 中两项准确率均最高的模型。验证集上两类之间的误判总数从 21 次降到 20 次，测试集上仍有 25 次。

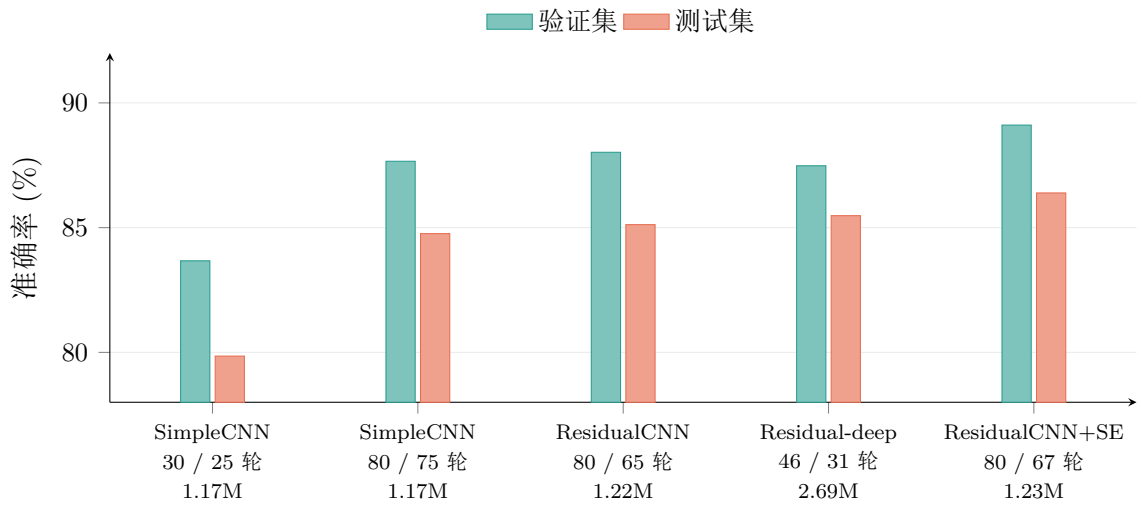


图 5: 各 CNN 模型的验证集与测试集准确率。

3.4 数据增强策略比较

第 3.3 节比较了网络结构的改动。本节同样以第 3.2 节训练 80 轮的 SimpleCNN 为基线，保留其结构，比较不同数据增强策略对总体准确率及 roses 与 tulips 识别结果的影响（附录 C）。加入 $\pm 20^\circ$ 旋转后，测试准确率提高 0.36 pp，验证准确率降低 0.55 pp，两组结果对旋转的评价并不一致。将随机裁剪的面积下限从 0.65 提高到 0.8 后，测试准确率仍为 84.76%，roses 的验证 F1 从 0.826 降至 0.786。保留更大的裁剪区域没有提高总体测试准确率，原裁剪设置对 roses 的识别表现更好。

关闭色相扰动后，验证和测试准确率均有所提高，roses 与 tulips 的验证 F1 也随之上升，测试准确率达到 85.66%。Mixup 将验证集上这两类之间的误判次数降至 17 次，其最佳验证检查点的测试准确率为 83.30%，低于基线。在本组实验中，关闭色相扰动是总体测试准确率最高的增强配置。

3.5 总结

在 SimpleCNN 基线上，调整数据增强对测试准确率的提升较小，改用 ResidualCNN+SE 后则达到本节最高的 86.39%。为进一步提高五类花卉的分类准确率，下一节采用 ImageNet 预训练模型，并在花卉数据集上微调。

4 基于 ImageNet 预训练的花卉分类

本节先在相同输入尺寸下比较三种预训练模型，再引入参数平均和测试时增强。随后分析各类别的识别结果，并针对 roses 与 tulips 的混淆比较两种输入尺寸。

4.1 模型选择与微调

模型选择兼顾分类准确率与参数量。MobileNetV3-Small 的参数量与上一节的 CNN 接近，用于考察轻量模型迁移后的表现。EfficientNetV2-M 和 ConvNeXt-Base 代表两种参数量较大的卷积架构，用于比较采用更大模型能取得怎样的分类准确率。

三个模型均加载 ImageNet 预训练权重，将原分类层替换为输出五类得分的全连接层，再用花卉训练集更新全部权重。初步比较沿用 224×224 像素输入及前文的训练、验证和测试集划分。

表 4 中，MobileNetV3-Small 微调 8 轮后的测试准确率为 92.56%，比 ResidualCNN+SE 高 6.17 pp。EfficientNetV2-M 与 ConvNeXt-Base 微调 5 轮后分别达到 96.19% 和 96.73%。

图 6 以 ResidualCNN+SE 的最佳验证准确率（89.11%）为参照。ConvNeXt-Base 在第 1 轮已超过该水平，EfficientNetV2-M 和 MobileNetV3-Small 在第 2 轮超过该水平。MobileNetV3-Small 有 1.52M 参数，微调 8 轮内的最佳验证准确率为 92.56%。这一结果表明，轻量模型也能通过预训练权重在少量训练轮次内取得较高的分类准确率。

表 4: 预训练模型的微调结果。

模型	参数量	epochs	验证准确率	测试准确率	Macro-F1
MobileNetV3-Small	1.52M	8	92.56%	92.56%	0.9239
EfficientNetV2-M	52.86M	5	94.56%	96.19%	0.9615
ConvNeXt-Base	87.57M	5	94.92%	96.73%	0.9665

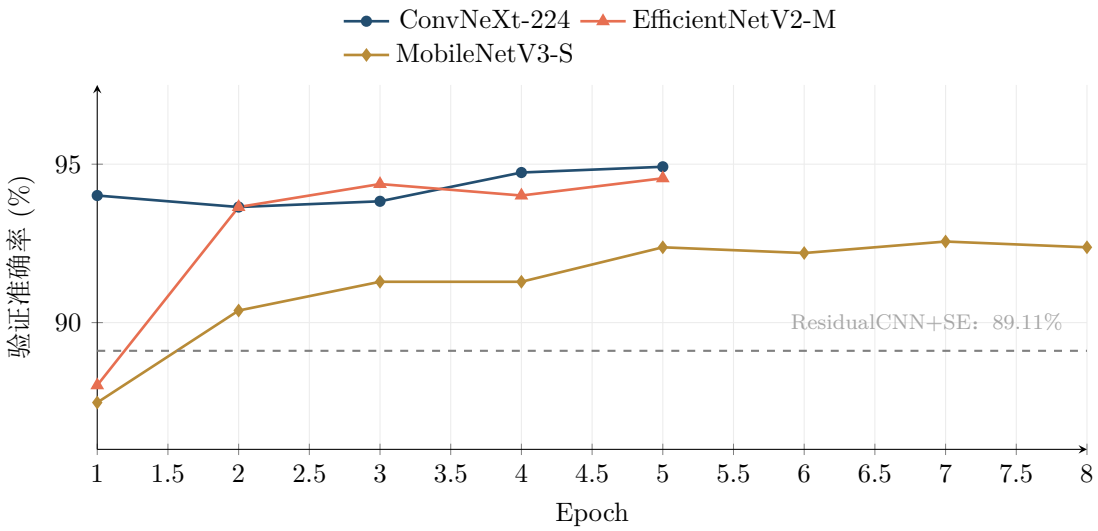


图 6: 预训练模型微调过程中的验证准确率变化图。

4.2 EMA 与 TTA

完成基础微调后，本节在 ConvNeXt-Base 和 EfficientNetV2-M 上尝试两项策略，分别用于减小单次参数更新造成的波动和降低预测对图像朝向的依赖。

在微调过程中，指数移动平均（EMA）对历次更新后的参数计算加权平均。为沿用基础微调的选模标准，每轮验证仍对按固定流程预处理的图像预测一次，再根据验证结果选择最佳轮次的 EMA 权重。选定权重后，在测试集上使用测试时增强（TTA），将原图和水平翻转图分别输入模型，再对两次预测的类别概率取平均。表 5 中，验证准确率用于选定模型，测试准确率用于评价加入翻转推理后的分类表现。

与表 4 的微调结果相比，采用这套训练与推理配置后，ConvNeXt-Base 的测试准确率从 96.73% 升到 96.91%，EfficientNetV2-M 从 96.19% 升到 96.73%。

表 5: 采用 EMA 和 TTA 的微调结果。

模型	输入边长（像素）	训练轮数	验证准确率	测试准确率	Macro-F1
ConvNeXt-Base	224	8	95.10%	**96.91%**	**0.9683**
EfficientNetV2-M	224	10	94.01%	96.73%	0.9669

4.3 各类别的识别表现

图 7 比较了 SimpleCNN、ResidualCNN+SE 与采用 EMA 和 TTA 的 ConvNeXt-Base（224 × 224 像素输入）。与 ResidualCNN+SE 相比，ConvNeXt-Base 在 daisy 与 sunflowers 上的 F1 提高约 9 pp，在 roses 与 tulips 上分别从 79.3% 和 81.6% 提高到 94.7% 和 94.6%。这两类的提升幅度在五类花卉中最大，但 F1 仍低于其余三类。

4.4 输入尺寸对分类表现的影响

为考察更大的输入能否改善 roses 与 tulips 的识别，本文将 ConvNeXt-Base 的输入提高到 256×256 像素，沿用第 4.2 节的 EMA 和 TTA。该配置微调 6 轮，学习率为 2×10^{-5}。相比表 5 中的 224 像素配置，验证准确率由 95.10% 升至 95.83%，roses 的验证 F1 由 0.898 升至 0.930，

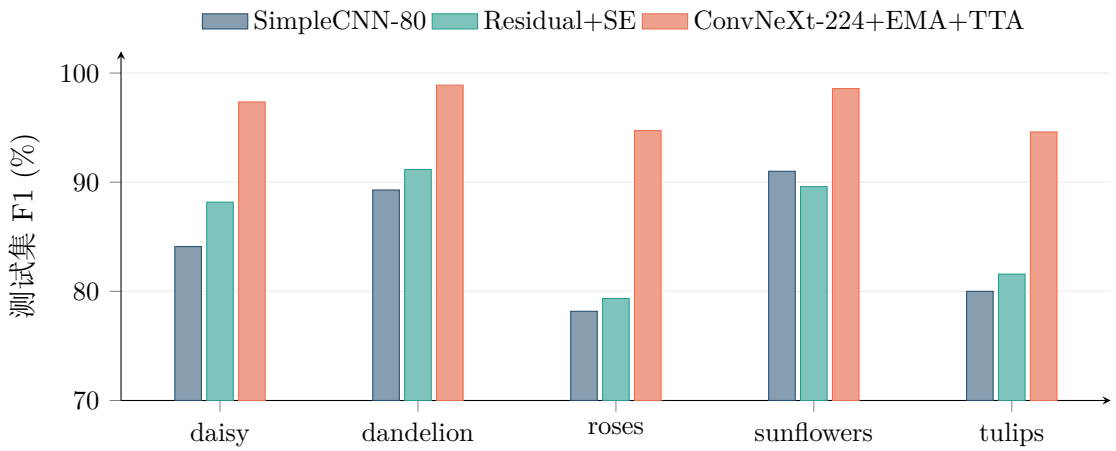


图 7: 三个代表性模型在测试集上的逐类 F1。

tulips 由 0.914 升至 0.934，两类之间的误判由 16 次降至 10 次。

在测试集上，256 像素配置的准确率为 96.73%，比 224 像素配置少判对 1 张图。两种配置的微调轮数和学习率也有差异，因此这里比较的是两套配置的实际表现。

5 双模型集成分类

第 4 节中，ConvNeXt-Base 的 256 像素配置减少了验证集上玫瑰与郁金香之间的误判，224 像素配置则取得了更高的总体测试准确率。为进一步提高分类准确率，本节比较不同架构和输入尺寸的模型组合，检验合并预测能否减少单个模型的分类错误。

5.1 成员选择与概率融合

将候选模型按不同组合进行等权概率平均后，ConvNeXt-Base-256 与 EfficientNetV2-M-224 的组合在验证集上取得最高准确率 96.37%，因此选用这两个模型。图 8 展示了集成的推理流程。分支 A 将图像短边缩放到 288 像素，再中心裁剪为 256×256 像素。分支 B 将短边缩放到 256 像素，再中心裁剪为 224×224 像素。

推理时，每个分支先对原图与水平翻转图分别前向，平均两次 softmax 输出；两个分支的概率再等权平均，取最大概率类别：

$$\bar{p}(y \mid x) = \frac{1}{4} \sum_{m \in \{A,B\}} \sum_{t \in \{0,1\}} p_m(y \mid T_t(x)), \qquad \hat{y} = \arg\max_y \bar{p}(y \mid x), \tag{7}$$

其中 T_0 为恒等变换，T_1 为水平翻转。两个分支的参数量分别为 87.57M 与 52.86M，合计约 140M；推理需要 4 次前向（两模型 × 翻转 TTA）。

5.2 分支训练

ConvNeXt-Base 分支使用 256×256 输入，训练 6 个 epoch，AdamW（$lr = 2\times10^{-5}$，$wd = 0.01$），余弦退火，标签平滑 0.1，EMA 衰减 0.995，batch size 32。EfficientNetV2-M 分支使用 224×224 输入，训练 5 个 epoch，AdamW（$lr = 10^{-4}$，$wd = 10^{-4}$），标签平滑 0.1，不使用 EMA。训练目标为标签平滑交叉熵（$\varepsilon = 0.1$）；两个分支都使用随机缩放裁剪、水平翻转与颜色抖动，验证和测试使用固定的缩放与中心裁剪。完整超参数见附录 B。

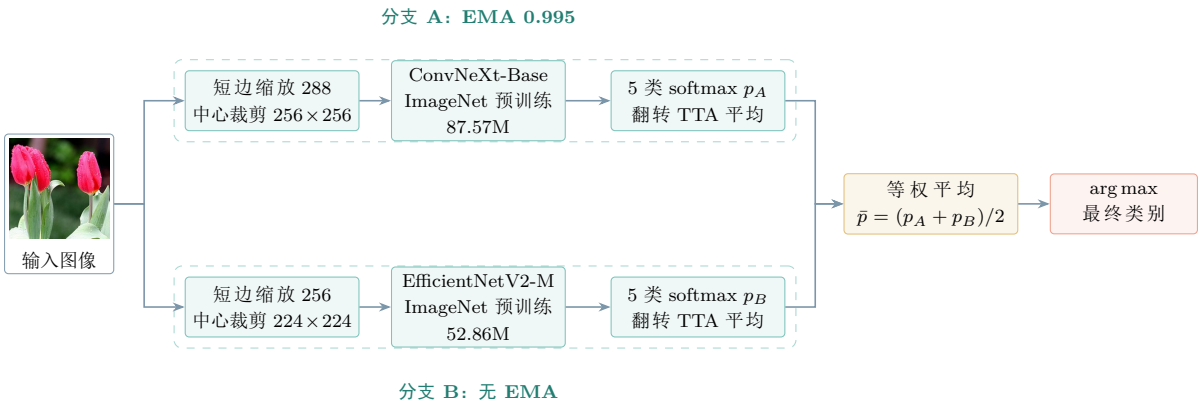


图 8: 双模型集成的推理流程。

5.3 单模型与集成模型的比较

表 6 比较了原测试集上使用翻转 TTA 的单模型与集成模型。双模型集成的准确率为 97.46%，Macro-F1 为 0.9742。与表现最好的单模型 ConvNeXt-224 相比，集成准确率高 0.55 pp，分类错误由 17 张降至 14 张。

表 6: 单模型与集成模型在原测试集上的表现。

方案	准确率	Macro-F1	错误数
ConvNeXt-224 + EMA + TTA（单）	96.91%	0.9683	17/551
ConvNeXt-256 + EMA + TTA（单）	96.73%	0.9669	18/551
EfficientNetV2-M-224 + TTA（单）	96.73%	0.9671	18/551
ConvNeXt-256 + EffNetV2-M（集成）	**97.46%**	**0.9742**	**14/551**

检查分类错误的图像时，发现有些样本的内容与标签不符。第 6 节介绍如何筛查和清洗这类样本，并在清洗后的测试集上重新评估模型。

6 标签清洗与误差分析

6.1 样本中的标签问题

检查模型判错的样本时发现，部分标为 roses 的图像拍的是车辆、建筑或食物，部分标为 tulips 的图像拍的是风信子。另有一些图像展示的是绘画、插画或蛋糕上的花形装饰。对这些样本，模型预测与原标签不一致也可能源于图像或标签本身的问题。

6.2 候选筛查与人工复核

首先，用训练好的 ConvNeXt-Base 对全部图像作预测，按模型的最高类别概率从低到高排列，并记录验证集和测试集上预测与标签不一致的样本。再用 ImageNet 预训练分类器筛查可能包含车辆、建筑、动物、景观、食物或人物活动的图像。人工复核时查看高分辨率原图，必要时查阅 Flickr 页面标题、作者标签和 oEmbed 元数据，以确认拍摄对象。

清洗移除了只包含无关场景或物体、以绘画或装饰表现花卉，以及能够确认标签与主体不符的图像。

移除的 57 张图像占数据集的 1.55%，其中训练集 37 张、验证集 13 张、测试集 7 张。表 7 按移除原因和数据集列出样本数，图 9 展示了六个例子。全部移除图像的编号见附录 D。

表 7: 清洗版的排除清单统计。占比以 57 张排除样本为分母。

问题类型	训练	验证	测试	合计	占排除数
无关场景或物体	24	4	3	31	54.4%
非真实花卉描绘	9	7	3	19	33.3%
类别不符（另一物种）	4	2	1	7	12.3%
合计	37	13	7	57	100%

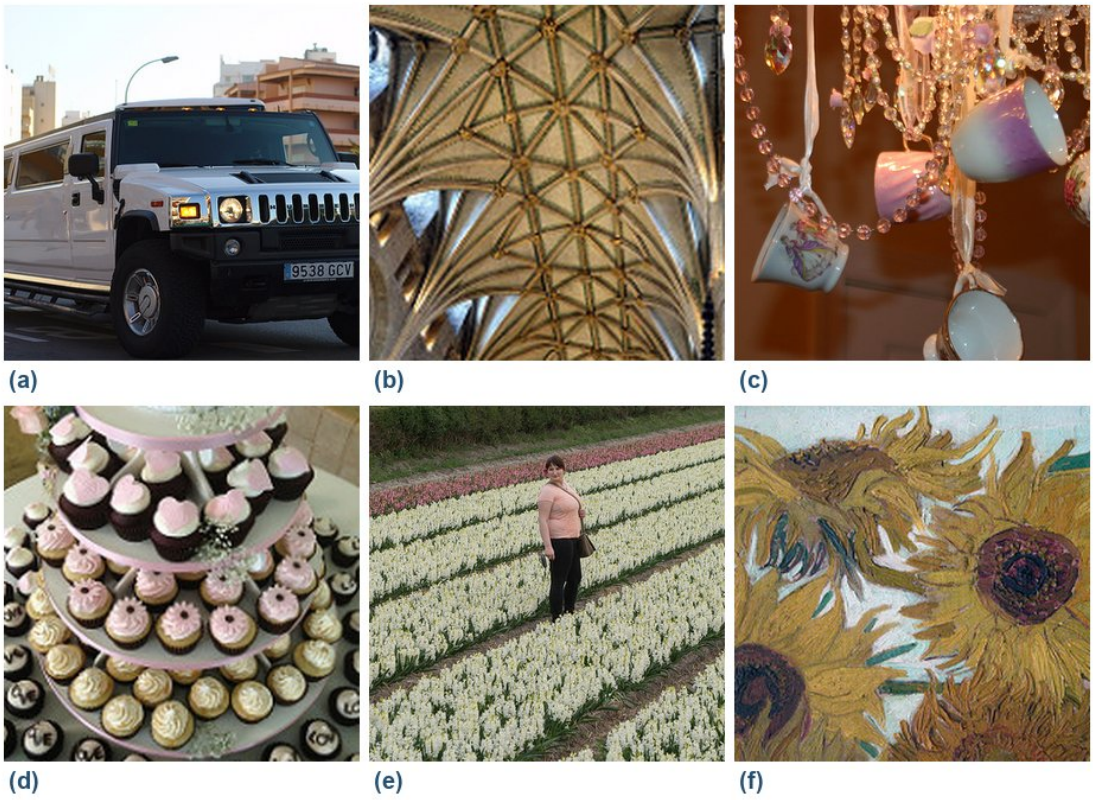


图 9: 标签问题示例。(a) 白色悍马车、(b) 哥特式穹顶、(c) 茶杯挂饰和 (d) 纸杯蛋糕塔均被标为 roses。(e) 风信子花田被标为 tulips。(f) 向日葵油画被标为 sunflowers。

6.3 标签清洗对分类表现的影响

移除问题样本后，训练集、验证集和测试集分别有 2,527、538 和 544 张图像，保留的图像继续使用原来的划分。本节沿用第 5 节的双模型集成，两个成员均使用在原训练集上得到的权重。表 8 对比该模型在清洗前后两个测试集上的表现。

移除 7 张确认存在标签问题的测试图像后，双模型集成的准确率为 97.43%，Macro-F1 为 0.9737，判错图像仍有 14 张。

如图 10 所示，14 张判错的图像中，有 3 张玫瑰被判为郁金香，4 张郁金香被判为玫瑰，两类之间的误判占全部错误的一半。各类别的精确率、召回率和 F1 见附录 E。

表 8: 同一双模型集成在清洗前后测试集上的表现。

测试数据	图像数	准确率	Macro-F1	错误数
清洗前	551	97.46%	0.9742	14
清洗后	544	97.43%	0.9737	14

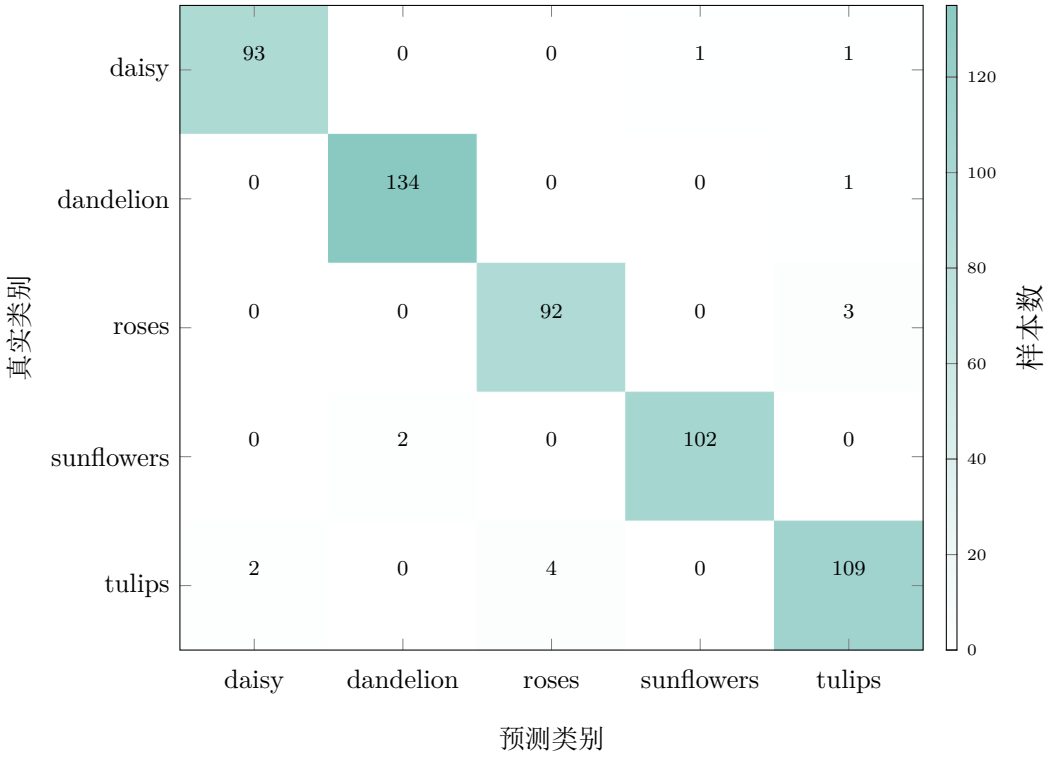


图 10: ConvNeXt-Base-256 与 EfficientNetV2-M-224 双模型集成在清洗后测试集上的混淆矩阵。

上述对照固定了模型权重。为考察清洗训练数据的影响，接下来固定清洗后的测试集，比较分别使用原训练集和清洗后训练集得到的两套集成。两组沿用相同的训练配置、随机种子和验证集。ConvNeXt-Base 从 ImageNet 权重开始，依次以 224 像素和 256 像素输入微调 8 轮和 6 轮。EfficientNetV2-M 同样从 ImageNet 权重开始，以 224 像素输入微调 5 轮。

表 9: 清洗训练数据前后两套集成在同一测试集上的表现。

两成员微调所用的训练集	判对图像数	准确率	Macro-F1
原训练集	530/544	97.43%	0.9737
清洗后训练集	529/544	97.24%	0.9719

如表 9 所示，用清洗数据训练的集成少判对 1 张图像，准确率由 97.43% 降至 97.24%。

综合两项对照，清洗测试集后，原集成判错的图像数保持为 14 张。在同一清洗后测试集上，用清洗后的训练集重新微调，集成少判对 1 张图像。两项对照的准确率变化均小于 0.2 pp，说明在本次数据划分与训练设置下，移除这些已确认的问题样本对集成的总体分类表现影响较小。

7 讨论与局限

7.1 有限样本下的五类花卉识别

本任务要求模型用约 2,500 张训练图像学习五类花卉的外观差异。随机初始化的 SimpleCNN 在训练后期仍能进一步拟合训练样本，验证准确率却趋于平稳。引入 ImageNet 预训练后，参数量接近自建 CNN 的 MobileNetV3-Small 已取得 92.56% 的测试准确率。这一结果说明，在本数据集的样本规模下，利用预训练模型已有的图像特征是改善分类表现的有效途径。

7.2 易混类别的识别局限

双模型集成在清洗后的测试集上判错 14 张图像，其中 7 张是把玫瑰认成郁金香，或把郁金香认成玫瑰。两类花卉各有多种花型，部分样本的花瓣形状和排列又很相近。区分外观相近的玫瑰与郁金香仍是模型的主要识别难点。

8 结论与展望

本文针对小规模图像数据集设计并验证了五类花卉分类模型。实验从自建 CNN 基线出发，比较了网络结构、数据增强与迁移学习方案，最终选用 ConvNeXt-Base-256 和 EfficientNetV2-M-224，通过等权平均两者的类别概率完成分类。该模型在清洗后的 544 张测试图像上达到 97.43% 的准确率和 0.9737 的 Macro-F1。

后续可补充不同花型、拍摄角度和花期的玫瑰与郁金香图像，并比较整图输入与花朵局部输入的识别表现。评价时可单独记录两类之间的误判数，检验模型能否更好地区分外观相近的花卉。

参考文献

[1] A. Krizhevsky, I. Sutskever, G. E. Hinton. ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems (NIPS)*, 2012: 1097–1105.

[2] K. He, X. Zhang, S. Ren, J. Sun. Deep residual learning for image recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016: 770–778. DOI: 10.1109/CVPR.2016.90.

[3] J. Hu, L. Shen, G. Sun. Squeeze-and-excitation networks. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018: 7132–7141. DOI: 10.1109/CVPR.2018.00745.

[4] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, S. Xie. A ConvNet for the 2020s. *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022: 11976–11986. DOI: 10.1109/CVPR52688.2022.01167.

[5] M. Tan, Q. V. Le. EfficientNetV2: Smaller models and faster training. *International Conference on Machine Learning (ICML)*, PMLR 139, 2021: 10096–10106.

[6] A. Howard, M. Sandler, G. Chu, et al. Searching for MobileNetV3. *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019: 1314–1324. DOI: 10.1109/ICCV.2019.00140.

[7] M.-E. Nilsback, A. Zisserman. Automated flower classification over a large number of classes. *Indian Conference on Computer Vision, Graphics and Image Processing (ICVGIP)*, 2008: 722–729.

[8] T.-Y. Lin, A. RoyChowdhury, S. Maji. Bilinear CNN models for fine-grained visual recognition. *IEEE International Conference on Computer Vision (ICCV)*, 2015: 1449–1457.

[9] X.-S. Wei, Y.-Z. Song, O. Mac Aodha, J. Wu, Y. Peng, J. Tang, J. Yang, S. Belongie. Fine-grained image analysis with deep learning: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(12), 2022. DOI: 10.1109/TPAMI.2021.3126648.

[10] H. Zhang, M. Cisse, Y. N. Dauphin, D. Lopez-Paz. mixup: Beyond empirical risk minimization. *International Conference on Learning Representations (ICLR)*, 2018.

[11] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, Z. Wojna. Rethinking the Inception architecture for computer vision. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016: 2818–2826. DOI: 10.1109/CVPR.2016.308.

[12] A. Tarvainen, H. Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. *Advances in Neural Information Processing Systems (NIPS)*, 2017: 6125–6134.

[13] T. G. Dietterich. Ensemble methods in machine learning. *Multiple Classifier Systems (MCS)*, LNCS 1857, 2000: 1–15. DOI: 10.1007/3-540-45014-9_1.

[14] C. G. Northcutt, L. Jiang, I. L. Chuang. Confident learning: Estimating uncertainty in dataset labels. *Journal of Artificial Intelligence Research*, 70, 2021. DOI: 10.1613/jair.1.12171.

[15] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, P. Parikh, D. Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *IEEE International Conference on Computer Vision (ICCV)*, 2017: 618–626. DOI: 10.1109/ICCV.2017.74.

[16] C. Shorten, T. M. Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6:60, 2019. DOI: 10.1186/s40537-019-0197-0.

A 预处理与数据增强示例

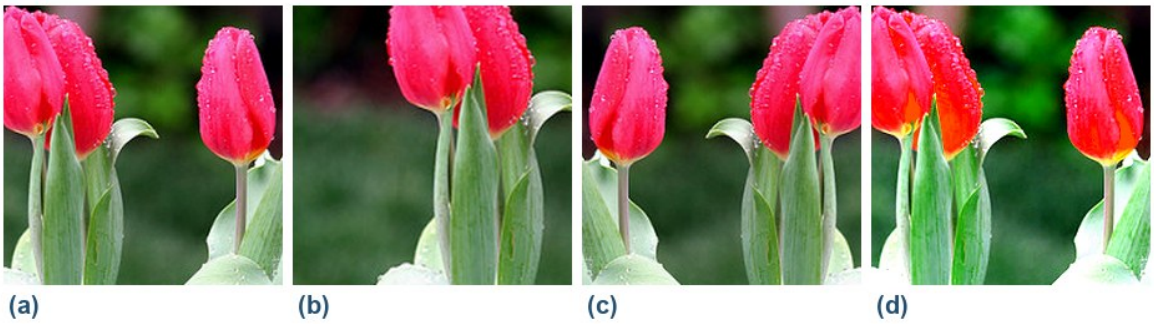


图 11: 同一张花卉图像的预处理与增强示例。(a) 中心裁剪，(b) 随机缩放裁剪，(c) 水平翻转，(d) 颜色抖动示意。

B 实验环境与训练配置

实验使用单张 NVIDIA GeForce RTX 5090 Laptop GPU、Python 3.12 和支持 CUDA 13.0 的 PyTorch，训练采用混合精度，随机种子为 42。表 10 中的训练上限和提前停止等待轮数均为配置值。各组使用 AdamW、余弦退火和每批 32 张图像。标签平滑系数为 0.1，Mixup 配置使用 0.05。

表 10: 各模型的训练配置。

配置	输入边长	训练上限	等待轮数	初始学习率	权重衰减	EMA 与 TTA
SimpleCNN（30 轮）	224	30	8	10^{-3}	10^{-4}	无
SimpleCNN（80 轮）及增强对照	224	80	15	10^{-3}	10^{-4}	无
ResidualCNN 系列	224	80	15	10^{-3}	10^{-4}	无
MobileNetV3-Small	224	8	8	3×10^{-4}	10^{-4}	无
EfficientNetV2-M	224	5	5	10^{-4}	10^{-4}	无
ConvNeXt-Base	224	5	5	10^{-4}	10^{-4}	无
EfficientNetV2-M	224	10	5	5×10^{-5}	0.01	有
ConvNeXt-Base	224	8	4	5×10^{-5}	0.01	有
ConvNeXt-Base	256	6	6	2×10^{-5}	0.01	有

输入边长的单位为像素。启用 EMA 时，衰减系数为 0.995，表中的 TTA 指水平翻转推理。256 像素的 ConvNeXt-Base 从表中训练上限为 8 轮的 224 像素模型检查点继续微调。比较清洗训练数据时，两组沿用这些配置，分别用各自训练得到的 224 像素检查点初始化下一阶段。

C 数据增强对照结果

各组均使用训练上限为 80 轮的 SimpleCNN。表 11 中，roses 和 tulips 的 F1 及两类之间的误判数均来自验证集。Mixup 的 α 为 0.2，同时将标签平滑系数从 0.1 调整为 0.05。

表 11: SimpleCNN 的数据增强对照结果。

设置	验证准确率	测试准确率	测试 Macro-F1	roses F1	tulips F1	两类互相误判数
基线	87.66%	84.76%	0.8451	0.826	0.831	21
旋转 ±20°	87.11%	85.12%	0.8488	0.836	0.817	20
裁剪 0.8–1.0	86.93%	84.76%	0.8456	0.786	0.835	21
关闭色相扰动	87.84%	**85.66%**	**0.8525**	**0.847**	0.849	21
Mixup $\alpha = 0.2$	**88.75%**	83.30%	0.8297	0.842	**0.854**	**17**

D 移除图像清单

表 12 列出清洗时移除的全部 57 张图像。文件名保留原数据集的图像编号。

表 12: 移除图像的编号与原数据集划分。

序号	图像路径（类别 / 文件名）	所属数据集
1	`daisy/1355787476_32e9f2a30b.jpg`	训练集
2	`roses/12045735155_42547ce4e9_n.jpg`	训练集
3	`roses/12450781274_eb78723921.jpg`	训练集
4	`roses/15174615529_144ae28bdb_n.jpg`	训练集
5	`roses/15750320284_22ef21c682.jpg`	训练集
6	`roses/16316557109_7fc55c1cbc_m.jpg`	训练集

序号	图像路径（类别 / 文件名）	所属数据集
7	roses/16334786972_1b3e71cab8_m.jpg	训练集
8	roses/16424992340_c1d9eb72b4.jpg	训练集
9	roses/180613732_3a7aba0b80_n.jpg	训练集
10	roses/2364976562_a184463083_m.jpg	训练集
11	roses/2863863372_605e29c03e_m.jpg	训练集
12	roses/319298955_0c72bd36bf.jpg	训练集
13	roses/3655527028_0fab2b547d_n.jpg	训练集
14	roses/3921794817_276eb4386b.jpg	训练集
15	roses/4248222578_b4d5868b32.jpg	训练集
16	roses/4292443009_3a2831b0b9_m.jpg	训练集
17	roses/5148639829_781eb7d346.jpg	训练集
18	roses/5193918046_d44e4fcd75_m.jpg	训练集
19	roses/5212885371_fe27c406a2_n.jpg	训练集
20	roses/6069602140_866eecf7c2_m.jpg	训练集
21	roses/8590442797_07fa2141c0_n.jpg	训练集
22	roses/9406573080_60eab9278e_n.jpg	训练集
23	sunflowers/7176729016_d73ff2211e.jpg	训练集
24	sunflowers/7270375648_79f0caef42_n.jpg	训练集
25	tulips/13910126337_53faf1d214_n.jpg	训练集
26	tulips/13910131718_731353d84c_n.jpg	训练集
27	tulips/14097328354_4f1469a170.jpg	训练集
28	tulips/14116780333_7836f4448c.jpg	训练集
29	tulips/14487705209_ea723109e1_m.jpg	训练集
30	tulips/15275144259_f9a18ec9cb.jpg	训练集
31	tulips/15275504998_ca9eb82998.jpg	训练集
32	tulips/17907238905_1ae121f8d9_m.jpg	训练集
33	tulips/3511776685_3635087b12_n.jpg	训练集
34	tulips/4522153453_06437ca3af_m.jpg	训练集
35	tulips/5674707464_dc18de05b1.jpg	训练集
36	tulips/6325571510_7544b27e57_n.jpg	训练集
37	tulips/7064813645_f7f48fb527.jpg	训练集
38	roses/15419696882_9394168a10_n.jpg	验证集
39	roses/17953368844_be3d18cf30_m.jpg	验证集
40	roses/2408236801_f43c6bcff2.jpg	验证集
41	roses/4256169180_55df2048a0.jpg	验证集
42	roses/7211616670_2d49ecb3a5_m.jpg	验证集

序号	图像路径（类别 / 文件名）	所属数据集
43	roses/8462246855_1bdfee7478.jpg	验证集
44	roses/8775267816_726ddc6d92_n.jpg	验证集
45	tulips/13513644515_a51470b899.jpg	验证集
46	tulips/16702188449_3dacce90b2_m.jpg	验证集
47	tulips/16862374316_4135908d4c_m.jpg	验证集
48	tulips/17202535346_ab828e779b.jpg	验证集
49	tulips/6948239566_0ac0a124ee_n.jpg	验证集
50	tulips/7070694881_e9a331fa4e_n.jpg	验证集
51	roses/12323085443_8ac0cdb713_n.jpg	测试集
52	sunflowers/418056361_1dfac1c151_n.jpg	测试集
53	tulips/13513851673_9d813dc7b0.jpg	测试集
54	tulips/15275190769_0ed7bbf490.jpg	测试集
55	tulips/15275199229_962387f24d.jpg	测试集
56	tulips/16862422576_5226e8d1d0.jpg	测试集
57	tulips/5687705933_55a8c2dbac.jpg	测试集

E 双模型集成的逐类指标

表 13: 双模型集成在清洗后测试集上的逐类指标。

类别	精确率	召回率	F1	图像数
daisy	0.979	0.979	0.979	95
dandelion	0.985	0.993	0.989	135
roses	0.958	0.968	0.963	95
sunflowers	0.990	0.981	0.986	104
tulips	0.956	0.948	0.952	115

F 完整代码

本文的完整源代码见以下 GitHub 仓库：
`https://github.com/The-time-forever/ML-Flowers-Basic`。